

Informe de Preprocesamiento de Datos

Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales

Director del proyecto: David Andrés Donoso Vargas

Servidor Público 5: Mateo Xavier Soliz Villafuerte

Fecha de entrega: 17 de octubre de 2025

Tabla de contenido

1.Introducción	3
2. Seguimiento de solicitud de datos	4
3. Limpieza de datos	5
4.Análisis Descriptivo	12
5.Resultados del Preprocesamiento	21
6. Conclusiones	24
7. Anexos	25

1. Introducción

El presente informe tiene como propósito documentar el proceso de preprocesamiento de datos realizado en el marco del proyecto de investigación “Estimación del Carbono Orgánico del Suelo a partir de Redes Neuronales de Grafos y Datos Multimodales Geoespaciales” PIS-24-09, correspondiente al Producto 2 del Proyecto. Esta etapa representa un componente esencial dentro del flujo metodológico general, pues constituye el punto de partida previo para el análisis cuantitativo y la modelización espacial del Carbono Orgánico del Suelo (SOC, por sus siglas en inglés) en el territorio ecuatoriano.

El SOC es un indicador clave de la calidad del suelo, la productividad agrícola y la dinámica de los ecosistemas terrestres. Desempeña un papel crucial en el ciclo global del carbono y en la mitigación del cambio climático. Su estudio y cuantificación permiten una mejor comprensión de los procesos de almacenamiento de carbono, los ciclos biogeoquímicos, la degradación de los suelos y las implicaciones ambientales derivadas del uso del territorio.

En este contexto, el desarrollo de métodos de modelización para la estimación y predicción del SOC resulta especialmente relevante, particularmente aquellos basados en enfoques de inteligencia artificial dada la coyuntura actual. Entre ellos, las redes neuronales de grafos (Graph Neural Networks, GNN) ofrecen nuevas posibilidades para modelar la variabilidad espacial del SOC a partir de información geoespacial heterogénea.

No obstante, la aplicación de estos modelos requiere disponer de datos precisos, consistentes y adecuadamente estructurados. Las bases de datos ambientales, especialmente aquellas construidas a partir de muestreos extensos y de diversas fuentes institucionales, suelen contener errores de digitación, inconsistencias en las coordenadas, registros incompletos o duplicados, y discrepancias en los sistemas de referencia geográfica utilizadas para cada uno de los registros. Por ello, antes del uso, análisis o modelización, es imprescindible aplicar un proceso de preprocesamiento de datos que garantice la calidad y coherencia de la información utilizada.

El objetivo general de esta etapa es asegurar que el conjunto de datos empleado en el estudio del SOC mantenga su integridad, precisión y compatibilidad para su posterior análisis mediante técnicas de aprendizaje profundo. En términos específicos, el preprocesamiento busca depurar la información disponible, verificar su validez espacial, eliminar inconsistencias y preparar el conjunto de datos para su integración en modelos de predicción geoespacial.

Unidad de Gestión de Investigación y Proyección Social

Edificio 3, Primer piso

Av. Ladrón de Guevara E11-253 y Andalucía

Teléfono: 2976300 Ext. 1066

En este sentido, el presente informe expone de manera sistemática las acciones realizadas para la depuración y preparación del conjunto de datos del SOC, siguiendo un enfoque reproducible, trazable y sustentado en principios de análisis geoespacial y minería de datos. Los resultados obtenidos constituyen la base para las siguientes etapas del proyecto, orientadas a la estimación y mapeo del carbono orgánico del suelo mediante técnicas avanzadas de inteligencia artificial.

2. Seguimiento de la solicitud de datos

Como parte del proceso de desarrollo del proyecto, se llevó a cabo la gestión, solicitud y recepción del conjunto de datos necesarios para la fase de preprocesamiento y análisis. Esta etapa tuvo como finalidad garantizar la disponibilidad de información confiable, actualizada y georreferenciada que permitiera caracterizar adecuadamente el SOC en el territorio ecuatoriano.

La obtención de los datos se realizó a través de la coordinación interinstitucional entre el equipo de investigación del proyecto y las entidades nacionales responsables. En particular, el conjunto de datos fue proporcionado en conjunto por dos instituciones oficiales: Ministerio de Agricultura, Ganadería y Pesca (MAGP) del Ecuador, y el Instituto Nacional de Meteorologías e Hidrobiológicas (INAHMI). Como resultado de este proceso, se obtuvo un conjunto de datos correspondiente al año 2021, entregado en formato .csv, con codificación Latin-1 y delimitación estándar por comas. El archivo se lo podrá encontrar en el Anexo 3 del presente informe.

El conjunto de datos recibido contiene 12.861 registros de muestras de suelo georreferenciadas, cada una identificada por un código único de perfil y acompañada de la siguiente información básica:

- **Coord_X y Coord_Y:** Coordenadas UTM que indican la localización precisa de la muestra.
- **Lim_sup y Lim_inf:** Límites superior e inferior de la profundidad de muestreo (en centímetros).
- **Da:** Densidad aparente del suelo (en g/cm³).
- **CO_g:** Contenido de carbono orgánico (en g/kg).

Cada registro corresponde a una muestra recolectada en el territorio continental ecuatoriano, abarcando distintas regiones del Ecuador y diversas profundidades de muestreo, lo que otorga al conjunto de datos una representatividad espacial significativa para el estudio.

La información recibida fue sometida a una verificación preliminar de integridad con el fin de asegurar que el archivo no presentara errores de lectura, codificación o formato que comprometieran su uso en las etapas posteriores. Este control inicial incluyó la comprobación de la cantidad total de registros, la detección de valores nulos, la coherencia de los encabezados de columna y la validación del tipo de datos en cada campo.

En consecuencia, el conjunto de datos obtenido se consideró adecuado como insumo base para las fases de exploración, depuración y transformación, las cuales se describen en las secciones posteriores. Dichas etapas buscan garantizar que los datos estén preparados para su integración en modelos de análisis espacial y redes neuronales de grafos, asegurando la trazabilidad y consistencia de la información empleada en el estudio.

3. Limpieza de datos

En esta etapa se aplicaron procedimientos de verificación, depuración y corrección dirigidos a identificar posibles errores en los datos, con el objetivo de eliminar estos registros inconsistentes o duplicados y asegurar la coherencia espacial de las muestras de SOC. Todos los análisis presentados en este informe los puede encontrar a detalle en el script de Python especificado en el anexo 4.

3.1 Verificación inicial del conjunto de datos

Una vez importado el archivo en formato .csv, se realizó una inspección preliminar mediante la librería *pandas*, con el fin de examinar la estructura general del conjunto de datos, las dimensiones del archivo, la tipología de las variables y la presencia de posibles valores faltantes o erróneos.

El conjunto de datos inicial constó de 12.861 registros distribuidos en siete columnas, correspondientes a los siguientes campos especificados en la Tabla 1:

Variables	Descripción	Tipo de Dato	Valores Nulos ó NaN
Perfil	Identificador único de la muestra	Object	0
Coord_X	Coordenada de longitud UTM Este (Easting)	Object	0
Coord_Y	Coordenada de latitud UTM Norte (Northing)	Object	0

Lim_sup	Límite superior de profundidad (cm)	Número Entero (int64)	0
Lim_inf	Límite inferior de profundidad (cm)	Número Entero (int64)	0
Da	Densidad aparente (g/cm ³)	Número Decimal (float64)	0
CO_g	Contenido de carbono orgánico (g/kg)	Número Decimal (float64)	0

Tabla 1: Lista de Variables del Data Set - SOC Ecuador – 2021

Con base en la Tabla 1, el conjunto de datos revela una estructura bien definida y coherente en cuanto a los tipos de datos y la completitud de la información registrada. En primer lugar, se observa que variables como el Perfil, la Coordenada en X e Y están clasificadas como tipo *object*, lo cual indica que contienen información de tipo categórico o textual. En este contexto, dichas columnas correspondan a identificadores de muestra y coordenadas geográficas almacenadas como texto, lo que podría requerir su conversión a formato numérico o geoespacial para su posterior procesamiento analítico.

Por otro lado, las variables Límite superior y Límite inferior presentan un tipo de dato *int64*, correspondiente a valores enteros, lo que sugiere que estas columnas almacenan información numérica discreta, relacionada con límites o profundidades de muestreo. Finalmente, la variable densidad aparente y la cantidad de carbono orgánico del suelo son de tipo *float64*, lo que implica la presencia de datos numéricos continuos con decimales.

En cuanto a la completitud de los datos, el conteo de valores nulos evidencia que ninguna de las columnas presenta valores faltantes, por ende, en todas las variables se reporta un 0 % de registros nulos presentes. Este resultado refleja una base de datos limpia y consistente, lo cual constituye una ventaja significativa para las etapas posteriores de análisis estadístico y modelado, ya que minimiza la necesidad de procedimientos de imputación. Sin embargo, aun se debe realizar un análisis más profundo con respecto a la calidad de información de cada registro del conjunto de datos.

Por ejemplo, durante esta revisión se detectaron inconsistencias en los valores de las coordenadas geográficas (Coord_X, Coord_Y), algunas de las cuales presentaban decimales atípicos o valores fuera de los rangos esperados para el sistema UTM en el territorio ecuatoriano, así como se lo presenta en la Figura 1. Estas irregularidades sugieren la presencia

de errores de digitación o discrepancias de formato, sistema de referencia o en la fase de registro original de las muestras.

Perfil	Coord_X	Coord_Y	Lim_sup	Lim_inf	Da	CO_g
CG1-P009	679562	9758034	0	24	1.41	11.60
CG1-P016	699434	9765581	0	5	1.33	34.80
CG1-P017	696893	9768441	0	30	1.29	39.44
CG1-P018	693618	9772357	0	20	1.29	40.02
CG1-P019	695768	9775445	0	15	1.03	35.96
...	...	...	...	...	...	...
CSp-ÑIII_C1-89-0052	723415.55	9959741.042	0	13	0.89	76.45

Figura 1: Conjunto de datos del SOC 2021 Ecuador - Inconsistencias en el sistema de referencia.

3.2 Detección y tratamiento de errores en registros con coordenadas atípicas

Para evaluar la validez de las coordenadas, se definieron rangos de referencia basados en los valores típicos del sistema UTM aplicable al Ecuador continental. Se consideraron como plausibles las coordenadas con valores *Easting* entre 100.000 y 900.000 metros, y *Northing* entre 1.000.000 y 11.000.000 metros.

En función de estos criterios, se clasificaron los registros en tres grupos:

- Registros válidos: coordenadas dentro de los rangos establecidos.
- Errores claros de digitación: coordenadas evidentemente incorrectas (por ejemplo, duplicación de valores X=Y o desplazamientos fuera del rango UTM).
- Casos plausibles pero inciertos: coordenadas ligeramente fuera del rango superior, posiblemente originadas por variaciones instrumentales o errores menores de redondeo.

Como resultado, se identificaron 535 registros con errores evidentes, los cuales fueron eliminados del conjunto de datos para evitar distorsiones en los análisis posteriores. En cambio, los 1.079 registros clasificados como plausibles fueron conservados, quedando sujetos a una verificación geoespacial posterior mediante su proyección a un sistema de referencia común.

3.3 Proyección geográfica y validación espacial

Con el propósito de garantizar la compatibilidad geográfica del conjunto de datos y facilitar su integración en entornos de análisis espacial, las coordenadas originales del sistema UTM (Universal Transverse Mercator) fueron proyectadas al sistema geodésico EPSG:4326 (WGS84), el cual utiliza las variables de latitud y longitud como referencia espacial estándar. Esta transformación permitió representar correctamente las muestras sobre cartografía oficial del Ecuador y verificar su correspondencia dentro de los límites del territorio nacional.

La validación espacial de los puntos se realizó empleando las librerías especializadas

El resultado de este proceso permitió clasificar las muestras de la siguiente manera:

- La Figura 2 ilustra la distribución espacial de las muestras tras la proyección al sistema de referencia geográfico EPSG:4326 (WGS84). En esta visualización se aprecia cómo la gran mayoría de los puntos se localizan correctamente dentro del territorio ecuatoriano, mientras que un número reducido de observaciones se encuentra disperso fuera de los límites continentales, presumiblemente debido a errores de digitación o inconsistencias en las coordenadas originales.



Una vez identificados los 30 registros situados fuera de los límites nacionales, estos fueron

eliminados del conjunto de datos, garantizando que todas las observaciones remanentes correspondieran exclusivamente a ubicaciones válidas dentro del Ecuador continental.

Finalmente, se generó una visualización interactiva mediante la librería *folium*, la cual permitió corroborar visualmente la distribución espacial de las muestras válidas y confirmar si todas estas se encuentran dentro de Ecuador continental, esto se lo puede visualizar en la Figura 3 y se lo puede comparar con la Figura 2. Este procedimiento aseguró la consistencia espacial del conjunto de datos, condición indispensable para los análisis y modelamientos geoespaciales que se desarrollarán en las etapas posteriores del proyecto.




Figura 3: Proyección de las muestras georreferenciadas del SOC al sistema geográfico EPSG:4326 (WGS84) de solo las muestras que están dentro de Ecuador.

3.4 Tratamiento de duplicados e inconsistencias

Una vez verificada la validez espacial de las muestras y depuradas las coordenadas geográficas, se procedió a realizar un análisis de consistencia interna de las mediciones del SOC. El objetivo de este proceso fue identificar la existencia de registros duplicados o inconsistentes en función de las variables espaciales (longitud y latitud) y los rangos de profundidad de muestreo, a fin de asegurar la coherencia del conjunto de datos previo a las etapas de análisis estadístico y modelamiento.

3.4.1 Identificación y depuración de registros duplicados en el conjunto de datos

En una primera etapa se procedió a identificar los registros duplicados en el conjunto de datos.

Se consideraron duplicados aquellos casos en los que todas las variables presentaban valores idénticos, es decir, coincidían en las coordenadas geográficas, los límites de profundidad y los valores de SOC (CO_g). En la Figura 4 se muestra el conjunto filtrado únicamente con los registros duplicados, los cuales ascienden a un total de 437. Esta duplicidad podría deberse a un manejo inadecuado de la base de datos durante su proceso de construcción.

	Perfil	Lim_sup	Lim_inf	Da	CO _g	longitud	latitud
4981	CG1-P181	0	5	6.80	39.4	-80.851797	-1.142589
5151	CG1-P181	0	5	6.80	39.4	-80.851797	-1.142589
5771	CG1-P181	5	45	1.80	10.4	-80.851797	-1.142589
5773	CG1-P181	5	45	1.80	10.4	-80.851797	-1.142589
5442	PN2-P253	0	20	1.22	7.1	-80.728300	-1.279355
...	...	...	...	...	...	...	...
4618	PN2-P218	0	35	12.50	72.5	-77.800030	0.816376
4619	PN2-P218	0	35	12.50	72.5	-77.800030	0.816376
4801	PN2-P218	0	35	12.50	72.5	-77.800030	0.816376
5347	PN2-P218	35	65	13.83	80.2	-77.800030	0.816376
5349	PN2-P218	35	65	13.83	80.2	-77.800030	0.816376

437 rows x 8 columns

Figura 4: Conjunto de datos de registros duplicados

Estos registros, al no aportar información nueva y representar una repetición exacta de mediciones previamente registradas, fueron eliminados del conjunto de datos. Este procedimiento permitió reducir el tamaño del conjunto de datos y evitar sesgos en los análisis descriptivos posteriores, garantizando que cada observación corresponda a una medición única y válida.

3.4.2 Identificación y tratamiento de registros duplicados, pero con diferentes mediciones de SOC

Posteriormente, se identificó un segundo tipo de duplicidad: registros que compartían la misma ubicación geográfica y los mismos límites de profundidad, pero presentaban diferentes valores de SOC (CO_g). En la Figura 5, se visualiza el conjunto de datos filtrado con los registros que cumple con esta particularidad, podemos ver que en la mayor parte de casos los valores del SOC no coinciden:

Se encontraron mediciones inconsistentes de SOC a la misma profundidad y ubicación:

	Perfil	Lim_sup	Lim_inf	Da	CO_g	longitud	latitud	geometry
5442	PN2-P253	0	20	1.22	7.1	-80.728300	-1.279355	POINT (-80.7283 -1.27935)
5444	PN2-P254	0	20	3.02	17.5	-80.728300	-1.279355	POINT (-80.7283 -1.27935)
5563	PN4-P203	0	10	6.68	38.7	-80.498054	-1.844633	POINT (-80.49805 -1.84463)
5564	PN4-P204	0	10	4.39	25.5	-80.498054	-1.844633	POINT (-80.49805 -1.84463)
5600	PN4-P229	0	20	2.68	15.5	-80.450317	-1.501881	POINT (-80.45032 -1.50188)
...	...	...	...	...	...	...	...	...
4572	PN4-P235	0	10	9.13	53.0	-78.722223	1.149667	POINT (-78.72222 1.14967)
5131	CG1-P021	0	10	3.30	19.1	-78.722223	1.149667	POINT (-78.72222 1.14967)
4878	PN1-P097	0	15	7.38	42.8	-78.037885	0.635378	POINT (-78.03788 0.63538)
5050	PN1-P097	0	15	7.38	42.8	-78.037885	0.635378	POINT (-78.03788 0.63538)
5426	PN2-P245	0	15	4.09	23.7	-78.037885	0.635378	POINT (-78.03788 0.63538)

90 rows x 8 columns

Figura 5: Conjunto de datos de registros inconsistentes de SOC a la misma profundidad y ubicación.

Este tipo de inconsistencia no puede atribuirse a un duplicado exacto, sino a posibles variaciones en las mediciones de laboratorio, errores de registro o diferencias metodológicas en la determinación del contenido de carbono. Dado que físicamente no es posible que en un mismo punto georreferenciado y a una misma profundidad existan distintos valores de SOC, se decidió aplicar un tratamiento mediante un promedio para cada uno de los registros que presenta este problema, para que de esta manera se pueda unificar estos registros.

El procedimiento consistió en:

1. Agrupar los registros duplicados por coordenadas geográficas (longitud y latitud) y por los límites de profundidad (Lim_sup, Lim_inf).
2. Calcular el valor promedio de SOC (CO_g) y, cuando fue pertinente, de la densidad aparente (Da) para cada grupo identificado.
3. Reemplazar los registros originales por una única observación representativa que contenga los valores promediados.

De esta forma, se logró mantener la información esencial del muestreo, reducir las inconsistencias internas del conjunto de datos y preservar la estructura espacial del mismo sin introducir sesgos derivados de valores contradictorios.

4. Análisis Descriptivo

4.1 Análisis de la profundidad de muestreo de cada medición del SOC

El análisis de la profundidad de muestreo constituye un paso esencial para garantizar la consistencia y calidad de los datos relacionados con el SOC. Antes de proceder con el análisis descriptivo y la detección de valores atípicos, se realizó una verificación preliminar de los límites de profundidad registrados en cada observación.

En particular, se revisaron los valores de los límites superior (*Lim_sup*) e inferior (*Lim_inf*) con el fin de identificar posibles inconsistencias, tales como casos en los que límite superior resultaban mayor que límite inferior o cuando la diferencia entre ambos representada por la variable Profundidad (*Profundidad_cm*) era menor o igual a cero. Los resultados de este análisis se presentan en la Figura 6.

Registros con errores básicos de profundidad:				
	Perfil	Lim_sup	Lim_inf	Profundidad_cm
0	PN3-P206	0	-7	-7
8578	CG6-P013	8	8	0

Figura 6: Registros con errores básicos de profundidad.

El procedimiento permitió detectar dos registros con errores básicos en la profundidad. En el primer caso (Perfil PN3-P206), se observó un valor negativo en el límite inferior (-7 cm), lo cual sugiere un error en la medición o en la digitación del dato. En el segundo caso (Perfil CG6-P013), los límites superior e inferior presentaban el mismo valor (8 cm), generando una profundidad nula. Ambos casos fueron considerados anomalías y se procedió a su exclusión del conjunto de datos, dado que podrían distorsionar el análisis estadístico posterior y afectar la interpretación de los patrones de muestreo.

Una vez depurados los registros erróneos, se calculó la variable Profundidad como la diferencia entre el límite superior e inferior, se obtuvo las siguientes estadísticas descriptivas presentadas en la Tabla 2:

Medida	Valor
Conteo (n)	11,431
Media	19.66 cm
Desviación estándar	8.72 cm
Mínimo	2 cm
1er Cuartil (Q1)	10 cm
Mediana	20 cm
3er Cuartil (Q3)	30 cm
Máximo	102 cm

Tabla 2: Estadísticas Descriptivas de la profundidad de muestreo

Los resultados indican que la profundidad promedio de muestreo fue de aproximadamente 19.66 cm, con una variabilidad moderada. La mayoría de las muestras se concentran en el rango de 10 a 30 cm, evidenciando una tendencia hacia muestreos superficiales, lo cual es coherente con el hecho de que las capas más cercanas a la superficie presentan mayores concentraciones de carbono orgánico debido a la descomposición de residuos vegetales y la actividad microbiana.

Detección de valores atípicos (Outliers)

Para identificar valores atípicos en la variable Profundidad (*Profundidad_cm*), se aplicó el método del rango intercuartílico (IQR), considerando como *outliers* aquellos registros con profundidades menores a $Q1 - 1.5 \times IQR$ o mayores a $Q3 + 1.5 \times IQR$. A partir de este criterio, se identificaron nueve posibles *outliers*, correspondientes a los perfiles *PM1-P094*, *PN5-P244*, *PN5-P243*, *CG5-P189* y *CG5-P177*, con profundidades comprendidas entre 65 y 102 cm.

Para contrastar estos resultados, podemos apreciar en la Figura 7, un gráfico de la distribución y un *box plot* para la variable profundidad:




Figura 7: Distribución de la Profundidad de muestreo.

El histograma evidencia la concentración de observaciones en los primeros 30 cm del perfil del suelo, mientras que el diagrama de caja permite visualizar los valores extremos detectados según el criterio del IQR. El valor máximo de 102 cm corresponde a un grupo reducido de muestras tomadas a mayor profundidad, que podrían representar condiciones edáficas específicas o, eventualmente, registros atípicos.

Adicionalmente, se identificaron los rangos de profundidad más frecuentes dentro del conjunto de datos, los cuales se detallan a continuación en la Tabla 3:

Rango de profundidad	Frecuencia
0 – 30 cm	2,990
21 – 30 cm	1,862
0 – 20 cm	1,262
0 – 25 cm	873
0 – 15 cm	842

Tabla 3: Tabla de Frecuencias del Rango de Profundidades

Estos resultados confirman que la mayoría de las mediciones fueron realizadas en rangos

superficiales, lo cual es coherente con las metodologías de muestreo orientadas a estimar la fracción activa del carbono orgánico del suelo. En conjunto, el análisis permite establecer una base sólida para el tratamiento estadístico posterior de las variables edáficas y la detección de patrones espaciales del SOC.

La variable Profundidad constituye un componente fundamental en el análisis del SOC, ya que la concentración de este elemento suele disminuir con la profundidad. Al examinar la distribución de los datos, se observa que la mayoría de las muestras se concentran en rangos superficiales particularmente entre 0 y 30 cm, lo cual es coherente con los estándares internacionales de muestreo de suelos, que priorizan la capa más activa en términos biogeoquímicos.

Sin embargo, la base de datos presenta múltiples registros con rangos similares, pero no equivalentes, tales como *0–20 cm*, *0–25 cm* o *0–30 cm*. Esta diversidad de intervalos introduce redundancia y variabilidad artificial, especialmente cuando provienen del mismo punto georreferenciado. Además, algunos registros exceden los 30 cm de profundidad o representan subcapas parciales del mismo perfil, lo que puede distorsionar los análisis si el objetivo es obtener una estimación uniforme del SOC en la superficie del suelo.

Por estas razones, resulta metodológicamente adecuado limitar el conjunto de datos a los valores correspondientes a la capa superficial (0–30 cm). Esta decisión permite homogeneizar la información y mejorar la comparabilidad entre observaciones. Los registros que superen este umbral o que carezcan de coherencia en su rango deben ser eliminados, mientras que aquellos con profundidades intermedias deben normalizarse bajo una categoría común, por ejemplo, *0–30 cm*.

Esta depuración no solo mejora la consistencia estadística del conjunto de datos, sino que también garantiza la validez pedológica del análisis, al centrarse en la fracción del suelo con mayor influencia biológica y económica. En consecuencia, se aplica al conjunto de datos una estrategia de limpieza que incluya: (1) la eliminación de registros con profundidades superiores a 30 cm, (2) la unificación de los rangos equivalentes, y (3) la conservación de un único rango representativo del SOC superficial. Por lo tanto, en este caso nuestro conjunto de datos luego de la aplicación de esta estrategia se queda con 11112 registros.

4.2 Análisis de la densidad aparente (DA) en cada medición del SOC

La densidad aparente (DA) constituye una variable clave en la estimación de las reservas de carbono orgánico del suelo, ya que permite relacionar el contenido de carbono con la masa de suelo por unidad de volumen. En esta sección, se analizó la distribución de la DA para todas las muestras comprendidas en el rango superficial de 0–30 cm, con el propósito de evaluar su coherencia, variabilidad y posibles valores atípicos.

Se realizó un análisis estadístico descriptivo sobre 11,112 registros válidos, obteniéndose los siguientes resultados presentados en la Tabla 4:

Medida	Valor
Conteo (n)	11112
Media	1.27 g/cm ³
Desviación estándar	1.01 g/cm ³
Mínimo	0.020 g/cm ³
1er Cuartil (Q1)	0.97 g/cm ³
Mediana	1.08 g/cm ³
3er Cuartil (Q3)	1.40 g/cm ³
Máximo	31.70 g/cm ³

Tabla 4: Estadísticas Descriptivas de la densidad aparente

Los resultados muestran que la densidad aparente promedio del suelo en las capas superficiales es de 1.26 g/cm³, con una variabilidad moderada ($\sigma = 1.00$). La mayoría de las observaciones se ubican entre 0.97 y 1.40 g/cm³, lo cual es coherente con valores típicos para suelos de textura media a fina.

Sin embargo, se identificaron valores extremos con magnitudes inusualmente altas (hasta 31.7 g/cm³), los cuales no son físicamente posibles para suelos naturales. Este tipo de registros probablemente corresponde a errores de medición, digitación o codificación durante la construcción de la base de datos.

Detección de valores atípicos (Outliers)

Para la identificación de valores anómalos se aplicó el método del rango intercuartílico (IQR), considerando como atípicos aquellos registros con valores inferiores a $Q1 - 1.5 \times IQR$ o superiores a $Q3 + 1.5 \times IQR$. Mediante este criterio se identificaron 569 posibles *outliers*, los

cuales corresponden principalmente a valores de DA anormalmente altos, como los observados en los perfiles PN2-P187 (3.55 g/cm^3), CG1-P181 (6.80 g/cm^3), PN9-P153 (6.57 g/cm^3), CG1-P023 (2.60 g/cm^3) y PN5-P263 (4.92 g/cm^3).

Estos valores exceden ampliamente los rangos esperados para suelos agrícolas o naturales ($0.8\text{--}1.6 \text{ g/cm}^3$), por lo que deben ser revisados individualmente. La presencia de dichos *outliers* puede alterar las medidas de tendencia central y dispersión, afectando la estimación de reservas de carbono y los procesos de modelado predictivo. Por ello, se debería conservar en el conjunto de datos los valores originales anotando una variable indicadora de *outliers* (*is_outlier = True*), para decidir posteriormente si su exclusión o corrección es necesaria según el contexto del análisis.

Para contrastar estos resultados, podemos apreciar en la Figura 8, la distribución y un diagrama de caja para la variable de Densidad Aparente:




Figura 8: Distribución de la Profundidad de muestreo.

El histograma evidencia que la mayor concentración de valores se encuentra entre 0.5 y 2.5 g/cm^3 , mostrando una distribución asimétrica hacia la derecha, con una cola extendida que representa los valores extremos identificados previamente. La mediana, representada por la línea roja discontinua, se sitúa alrededor de 1.08 g/cm^3 , confirmando la concentración principal de datos en el rango típico para suelos superficiales.

El diagrama de caja permite visualizar con claridad los puntos fuera del rango intercuartílico, correspondientes a mediciones atípicas. Estos puntos, situados a la derecha del rango principal, reflejan la existencia de densidades anómalas posiblemente derivadas de errores de registro o condiciones excepcionales del terreno.

4.3 Análisis de la cantidad de Carbono Orgánico del Suelo (SOC)

En este apartado se realiza un análisis descriptivo y exploratorio de la variable CO_g, que representa la cantidad de carbono orgánico del suelo expresada en g/kg, correspondiente a los horizontes superficiales del suelo (0–30 cm) en el territorio ecuatoriano. Se realizó un análisis estadístico descriptivo sobre 11,112 registros válidos, obteniéndose los siguientes resultados presentados en la Tabla 5:

Medida	Valor
Conteo (n)	11112
Media	32.03 g/kg
Desviación estándar	27.32 g/kg
Mínimo	0.060 g/kg
1er Cuartil (Q1)	14.27 g/kg
Mediana	24.36 g/kg
3er Cuartil (Q3)	41.59 g/kg
Máximo	410.00 g/kg

Tabla 5: Estadísticas Descriptivas del Carbón Orgánico del Suelo

El conjunto de datos utilizado comprende 11,112 registros válidos, cuyos valores presentan una marcada variabilidad. De acuerdo con las estadísticas descriptivas, la media del contenido de carbono orgánico es de 32.03 g/kg, con una desviación estándar de 27.33 g/kg, lo que evidencia una alta dispersión entre las muestras. El valor mínimo registrado es de 0.06 g/kg, mientras que el máximo alcanza 410 g/kg, reflejando una amplitud considerable en los niveles de SOC medidos. Los percentiles indican que el 25% de las observaciones presentan valores inferiores a 14.27 g/kg, la mediana se sitúa en 24.36 g/kg y el 75% de los registros no supera los 41.59 g/kg, lo que sugiere una distribución asimétrica y sesgada hacia valores elevados.

Detección de valores atípicos (Outliers)

Mediante la aplicación del método del rango intercuartílico (IQR) se identificaron 578 posibles valores atípicos, equivalentes al 5.2% del total de registros. Estos *outliers* corresponden a observaciones con valores de SOC significativamente alejados del rango intercuartílico típico, que podrían estar asociados a errores de medición, condiciones edáficas excepcionales o suelos con acumulaciones orgánicas inusualmente altas.

En la Figura 9, se aprecian algunos de estos casos, donde los valores de SOC superan los 90 g/kg, alcanzando incluso 204 g/kg en ciertos perfiles.

Número de posibles outliers: 578					
	Perfil	Lim_sup	Lim_inf	CO_g	
15	CSp-NIV_E2-98-0055	0	5	92.10	
32	CSp-NVII_D2-85-0062	0	5	204.12	
33	CSp-NVII_F4-85-0050	0	5	90.84	
39	CSp-NV_F4-89-0018	0	5	106.38	
49	CSp-NIII_A3-89-0034	0	5	89.70	

Figura 9: Tabla de principales Outliers relacionados al SOC.

Para contrastar estos resultados, podemos apreciar en la Figura 8, la distribución y un diagrama de caja para la variable de Densidad Aparente:




Figura 10: Distribución del SOC.

La representación gráfica de la distribución del SOC (Figura 10) mediante histograma y

diagrama de caja (boxplot) permite visualizar con mayor claridad la concentración y dispersión de los datos. Se observa que la mayoría de los valores se concentran entre 10 y 50 g/kg, con una mediana cercana a 24.36 g/kg, marcada mediante una línea discontinua roja. La presencia de una cola larga hacia la derecha confirma el sesgo positivo y la existencia de valores extremos, mientras que el boxplot resalta múltiples puntos individuales ubicados por encima del rango intercuartílico superior, correspondientes a los *outliers* previamente identificados.

La caja central del boxplot muestra que el 50% central de las observaciones se concentra entre aproximadamente 14 y 42 g/kg, lo que refleja una distribución heterogénea con tendencia a valores bajos en suelos superficiales, probablemente asociados a áreas agrícolas o zonas intervenidas. Por otro lado, los valores más altos se vinculan con suelos de vegetación densa, ecosistemas naturales o regiones con alta acumulación de materia orgánica.

Identificación de Outliers

Para una gestión más eficiente de los valores atípicos, se incorporó al conjunto de datos una columna indicadora denominada `is_outlier_SOC`, que clasifica cada registro como True si el valor de SOC se encuentra fuera de los límites del IQR, y False en caso contrario. Esta estrategia permite:

- Preservar la integridad del conjunto de datos original, evitando la eliminación inmediata de valores que podrían tener relevancia ecológica o agronómica.
- Facilitar la filtración o exclusión de *outliers* en etapas posteriores de modelamiento, reduciendo su impacto sobre métodos estadísticos o de aprendizaje automático sensibles a valores extremos.
- Otorgar flexibilidad analítica, permitiendo decidir de forma informada si los valores extremos deben ser corregidos, suavizados o mantenidos según su contexto geográfico.

En total, 578 registros fueron clasificados como outliers y se conservaron identificados para futuras fases de preprocesamiento, limpieza y modelización del carbono orgánico del suelo. Este procedimiento garantiza una mayor robustez y confiabilidad en las estimaciones y análisis posteriores, al minimizar el efecto distorsionador de los valores extremos sobre la estructura estadística del conjunto de datos.

El análisis realizado evidencia que el contenido del SOC presenta una alta variabilidad espacial y una marcada asimetría en su distribución, lo que refleja la influencia significativa de las condiciones locales del suelo y de los distintos usos del territorio. La detección de valores extremos pone de manifiesto la heterogeneidad existente en el país y subraya la importancia de implementar procedimientos rigurosos de control y depuración de estos datos. En conjunto, este análisis representa una etapa esencial de validación y limpieza previa a la aplicación de modelos de interpolación espacial o a la estimación del carbono orgánico del suelo a escala nacional.

5. Resultados del Preprocesamiento

5.1 Distribución Espacial del SOC (con *Outliers*)

En la etapa inicial del análisis espacial se representó la distribución espacial de las muestras del SOC en Ecuador considerando la totalidad de los registros disponibles, incluidos los valores atípicos. La visualización de la Figura 11 nos permite identificar una notable variabilidad espacial, con concentraciones más elevadas principalmente en la región occidental y en ciertos sectores de la Sierra, mientras que la región amazónica presenta valores significativamente menores. La presencia de *outliers* refleja la amplitud natural de las condiciones edáficas del país y puede estar asociada tanto a características ambientales

particulares como a posibles inconsistencias o errores en los datos de origen.




Figura 11: Distribución Espacial del SOC con Outliers.

No obstante, la inclusión de estos valores extremos puede afectar la calidad de los modelos estadísticos y espaciales, generando sesgos en las estimaciones. Por esta razón, se consideró necesario aplicar posteriormente procedimientos de detección y depuración de valores anómalos realizados en las secciones 4.1, 4.2 y 4.3, con el fin de obtener una representación más robusta y confiable del comportamiento del SOC en el territorio ecuatoriano.

5.2 Distribución Espacial del SOC (sin Outliers)

Posteriormente, se realizó una depuración del conjunto de datos para eliminar los valores atípicos identificados en la etapa previa, obteniéndose una representación espacial del SOC más coherente y homogénea. La visualización sin *outliers* permite observar una distribución más continua y representativa del comportamiento real del SOC en Ecuador, destacándose nuevamente mayores concentraciones en la región Sierra y en ciertas zonas de la Costa,

mientras que en la Amazonía los valores se mantienen relativamente bajos. Esto se puede observar en la Figura 12:




Figura 12: Distribución Espacial del SOC sin Outliers.

La exclusión de los valores extremos contribuyó a reducir la dispersión y mejorar la calidad de los datos, favoreciendo la estabilidad de los modelos estadísticos y la precisión en los procesos de interpolación espacial. Este ajuste garantiza una base de análisis más confiable para las siguientes etapas del estudio y una interpretación más realista de la variabilidad edáfica nacional.

En contraste, la visualización sin *outliers* presenta una distribución más uniforme y coherente, en la cual se identifican con mayor claridad los patrones espaciales reales del SOC. Se mantienen las concentraciones más elevadas en la región Sierra y en zonas específicas de la Costa, mientras que la Amazonía muestra valores relativamente menores. La eliminación de los valores atípicos permitió reducir la dispersión de los datos y mejorar la estabilidad de los

modelos analíticos, asegurando resultados más representativos y fiables. En consecuencia, este proceso de depuración constituye un paso fundamental para garantizar la robustez de las etapas posteriores del análisis espacial y la interpretación de la dinámica del carbono orgánico en los suelos del Ecuador.

6. Conclusiones

El preprocesamiento del conjunto de datos de muestras de Carbono Orgánico de Suelo (SOC) para Ecuador 2021 permitió consolidar una base confiable y trazable, integrando registros provenientes del Ministerio de Agricultura y Ganadería del Ecuador (MAGP) y del Instituto Nacional de Meteorología e Hidrología del Ecuador (INAMHI) (12.861 observaciones), mediante un flujo reproducible que incluyó verificación de integridad, estandarización de codificación y proyección a EPSG:4326 (WGS84), garantizando compatibilidad para análisis geoespacial y modelado posterior.

La depuración espacial y estructural fue efectiva: se identificaron y corrigieron errores de coordenadas, eliminando 535 registros manifiestamente erróneos y 30 puntos fuera del territorio nacional. Además, se suprimieron 437 duplicados exactos y se consolidaron observaciones coincidentes en ubicación y profundidad mediante promediación, preservando la información esencial sin introducir sesgos.

El enfoque pedológico se homogeneizó al centrarse en el horizonte superficial 0–30 cm, lo que permitió comparaciones consistentes entre muestreos y mejoró la validez del análisis. Tras esta depuración, el conjunto de datos operativo quedó conformado por 11.112 registros, listos para análisis posteriores.

El control de calidad métrica y gestión de *outliers* reveló patrones consistentes: para densidad aparente (DA), la mayoría de los valores se concentró entre aproximadamente 0,97 y 1,40 g/cm³, identificándose 569 posibles anomalías. Para SOC (CO_g), la media fue 32,03 g/kg, con marcada asimetría y 578 posibles outliers (~5,2%). Todos los valores atípicos fueron señalados explícitamente, manteniendo la integridad del conjunto de datos y permitiendo decisiones informadas durante la modelización.

El análisis espacial evidenció patrones robustos: los mapas iniciales mostraban alta variabilidad y puntos extremos capaces de sesgar las interpolaciones. Tras la depuración, la distribución espacial presentó mayor coherencia, con concentraciones más elevadas de SOC

en la Sierra y en determinadas zonas de la Costa, y valores relativamente menores en la Amazonía, permitiendo una interpretación más precisa de la estructura geográfica del carbono orgánico del suelo.

El resultado final es un conjunto depurado (DF_Final_procesado_SOC_Ecuador_2021.xlsx) y documentado con integridad espacial y estadística, apto para métodos de interpolación y para su aplicación en redes neuronales de grafos para la estimación de SOC. Esto constituye una base sólida para obtener predicciones estables y confiables a escala nacional.

Lim_sup	Lim_inf	Perfil	Da	CO_g	longitud	latitud	Rango_profundidad	Profundidad_cm	Rango_profundidad_normalizado	outlier_profundidad	outlier_DA	is_outlier_SOC
0	2	CSp-NVI_C2-98-0057	1.05	50	-79.545505	-3.4736621	0–2 cm	2	0–30 cm	FALSO	FALSO	FALSO
0	2	PN2-P187	3.55	20.6	-79.066997	1.05037806	0–2 cm	2	0–30 cm	FALSO	VERDADERO	FALSO
0	2	CSp-NVII_C3-91-0061	1.02	29	-78.889208	-4.5950346	0–2 cm	2	0–30 cm	FALSO	FALSO	FALSO
0	3	CSp-NVII_A1-97-0068	1.02	29	-78.800929	-4.0874246	0–3 cm	3	0–30 cm	FALSO	FALSO	FALSO
0	3	CSp-OII_F1-99-0014	1.04	12.82	-77.474178	0.31744345	0–3 cm	3	0–30 cm	FALSO	FALSO	FALSO
0	4	CSp-NVI_D2-81-0046	1	26.74	-79.066285	-3.3461817	0–4 cm	4	0–30 cm	FALSO	FALSO	FALSO
0	5	CG1-P181	6.8	39.4	-80.851797	-1.1425889	0–5 cm	5	0–30 cm	FALSO	VERDADERO	FALSO
0	5	PN9-P153	6.57	38.1	-80.126967	-3.8997188	0–5 cm	5	0–30 cm	FALSO	VERDADERO	FALSO
0	5	CG1-P023	2.6	15	-80.034848	0.8002015	0–5 cm	5	0–30 cm	FALSO	VERDADERO	FALSO
0	5	PN5-P263	4.92	28.5	-79.940084	0.81585422	0–5 cm	5	0–30 cm	FALSO	VERDADERO	FALSO
0	5	PN8-P245	8.09	46.9	-79.931178	-0.0376121	0–5 cm	5	0–30 cm	FALSO	VERDADERO	FALSO
0	5	CG3-P033	2.4	13.9	-79.817437	-1.5701736	0–5 cm	5	0–30 cm	FALSO	VERDADERO	FALSO
0	5	CSp-NVI_C2-87-0066	1.01	66.8	-79.737728	-3.3548212	0–5 cm	5	0–30 cm	FALSO	FALSO	FALSO
0	5	CSp-NVI_A4-100-0021	1.03	42.3	-79.73892	-3.2028704	0–5 cm	5	0–30 cm	FALSO	FALSO	FALSO
0	5	CSp-NIV_E2-98-0055	0.94	92.1	-79.744911	-1.7209659	0–5 cm	5	0–30 cm	FALSO	FALSO	VERDADERO
0	5	CG6-P015	0.79	27.84	-79.71883	-1.5397964	0–5 cm	5	0–30 cm	FALSO	FALSO	FALSO
0	5	PN9-P167	6.64	38.5	-79.664097	-3.9339575	0–5 cm	5	0–30 cm	FALSO	VERDADERO	FALSO
		CSp-NIV_E2										

Figura 1: Conjunto de Datos Preprocesado del SOC - Ecuador - 2021.

En síntesis, el preprocesamiento realizado mejoró significativamente la calidad, coherencia y utilidad analítica del conjunto de datos SOC–Ecuador 2021. La combinación de controles espaciales, tratamiento de duplicados, normalización de profundidades y gestión explícita de *outliers* permitió reducir fuentes de sesgo y clarificar los patrones geográficos del SOC, asegurando que las etapas de modelización y mapeo del recurso edáfico se puedan ejecutar con rigor y confiabilidad.

7. Anexos

Unidad de Gestión de Investigación y Proyección Social
Edificio 3, Primer piso
Av. Ladrón de Guevara E11-253 y Andalucía
Teléfono: 2976300 Ext. 1066

Anexo 1. Formato de solicitudes enviada al Ministerio de Agricultura y Ganadería (MAG), a través del Oficio Nro. INAMHI-DEI-2025-400-TEMP

[Solicitud Datos SOC - Ecuador MAG-INAMHI-DEI-2025-400](#)

Anexo 2. Respuesta oficio Nro. INAMHI-DEI-2025-0043-O – Solicitud de información sobre Carbono Orgánico del Suelo (SOC)

[Respuesta oficio Nro. INAMHI-DEI-2025-0043-O - Solicitud de información sobre Carbono Orgánico del Suelo \(SOC\).pdf](#)

Anexo 3. Base de Datos del SOC – Ecuador 2021

[Base de datos de SOC - Ecuador - 2021.csv](#)

Anexo 4. Script Python – Preprocesamiento de Datos de SOC – Ecuador 2021

[Producto 2 Proyecto PIS 24 09.ipynb](#)

Anexo 5. Delimitación Territorial de Ecuador Continental en formato .shp

[Delimitación Territorial - Ecuador Continental.rar](#)

Anexo 6. Base de Datos del SOC 2021 – Procesada

[DF Final procesado SOC Ecuador 2021.xlsx](#)

Elaborado por:

Nombre: Mateo Xavier Soliz Villafuerte

Servidor Público 5

Aprobado por:

Nombre: David Andrés Donoso Vargas

Director del Proyecto PIS-24-09