

Informe de Selección y Diseño de Arquitecturas de Redes Neuronales (énfasis en GNN)

Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales

Director del proyecto: Miguel Alfonso Flores Sánchez

Consultora servicios profesionales: Mateo Xavier Soliz Villafuerte

Fecha de entrega: 18 de noviembre de 2025

Tabla de contenido

1. Introducción.....	3
2. Revisión de Literatura	4
2.1 Graph Convolutional Networks (GCN)	4
2.2 GraphSAGE (Sample and Aggregate).....	5
2.3 Graph Attention Network (GAT)	7
2.4 Adaptive Graph Convolutional Network with Spatial Autocorrelation (ASI- GCN)	8
2.5 Comparación de arquitecturas.....	9
3. Diseño de modelos/arquitecturas	11
3.1 Arquitectura 1: Graph Convolutional Network (GCN).....	11
3.2 Arquitectura 2: GraphSAGE (Configuración PESAGE)	12
3.3 Arquitectura 3: Graph Attention Network (GAT).....	13
3.4 Arquitectura 4: ASI-GCN (Adaptive Spatial GCN)	13
4. Resultados esperados	16
4.1 Desempeño predictivo esperado.....	17
4.2 Coherencia espacial de las predicciones.....	17
4.3 Potencial contribución a la gestión del suelo	17
5. Conclusiones	17
6. Referencias bibliográficas.....	18

1. Introducción

La estimación precisa del Carbono Orgánico del Suelo (SOC) desempeña un rol central en el ciclo global del carbono, actuando simultáneamente como fuente y sumidero, e influyendo de manera determinante en la salud edáfica, la fertilidad y la funcionalidad ecosistémica general (Zhao & Efremova, 2023). Dado su impacto directo sobre las dinámicas climáticas, el monitoreo riguroso del SOC es imperativo para el diseño de políticas de agricultura sostenible y la mitigación del cambio climático (Zhao & Efremova, 2023).

Históricamente, la cartografía digital de suelos (DSM) se ha apoyado en el paradigma formalizado por McBratney et al. (2003), utilizando métodos geoestadísticos como el Kriging o algoritmos de aprendizaje automático como Random Forest (Wadoux et al., 2020). Sin embargo, estos enfoques presentan limitaciones estructurales significativas. El Kriging universal, por ejemplo, asume que las observaciones provienen de un proceso Gaussiano subyacente y estacionario, una suposición restrictiva que a menudo no se cumple en datos reales de conteo o distribuciones de cola pesada típicas de propiedades del suelo (Appleby et al., 2023; Wadoux et al., 2020). Además, los métodos tradicionales tienden a suavizar excesivamente las variaciones locales y luchan por capturar dependencias espaciales complejas de alto orden, especialmente en escenarios con datos escasos o heterogéneos (Tao et al., 2025; Yuan, 2025).

La incorporación de técnicas de Deep Learning, específicamente las Redes Neuronales entre ellas las Convolucionales (CNN), marcó un avance notable al integrar información del DSM. Estudios previos, como los de Padarian et al. (2019), demostraron que las CNN que incorporan información contextual pueden reducir el error de predicción en aproximadamente un 30% en comparación con las técnicas convencionales que solo utilizan información puntual de covariables. No obstante, las CNN están inherentemente diseñadas para datos euclidianos estructurados en cuadrículas regulares (grids) o imágenes, lo que limita su aplicabilidad directa en dominios irregulares y redes de sensores dispersos, comunes en los muestreos de suelo (Li et al., 2023; Wu et al., 2021).

En este contexto, las Redes Neuronales de Grafos (GNN) emergen como el nuevo estado del arte para el modelado espacial. A diferencia de las CNN, las GNN pueden operar sobre estructuras de datos no euclidianas, donde el número de conexiones varía y los nodos no están ordenados, permitiendo modelar explícitamente las dependencias espaciales irregulares (Zhu et al., 2021; Li et al., 2023). Mediante mecanismos de paso de mensajes (message passing), las GNN capturan interdependencias complejas, por ejemplo, la interdependencia entre el SOC y las características climáticas multifacéticas, integrando codificadores posicionales para representar dependencias geográficas críticas (Zhao & Efremova, 2023). Además, arquitecturas recientes han demostrado capacidad inductiva, permitiendo generalizar el aprendizaje a ubicaciones no muestreadas sin necesidad de reentrenamiento completo, una ventaja crucial sobre métodos transductivos como la completación de matrices (Wu et al., 2021). Al desacoplar la proximidad geográfica de la similitud de atributos y modelar la anisotropía espacial, las GNN ofrecen una representación

más robusta y coherente de la variabilidad del suelo que los modelos predecesores (Yuan, 2025).

2. Revisión de Literatura

En el dominio de la modelización geoespacial las GNN han evolucionado para abordar las limitaciones críticas de los métodos de convolución tradicionales, los cuales prosperan en estructuras de cuadrícula regular, pero fallan en dominios irregulares. A diferencia de las CNN, que asumen una topología euclidiana fija, las GNN operan sobre estructuras de datos no euclidianas donde el número de conexiones varía y los nodos carecen de un orden predeterminado (Zhu et al., 2021). Esto es fundamental para capturar dependencias espaciales complejas en redes de sensores o puntos de muestreo distribuidos irregularmente en un área de estudio (Wu et al., 2021).

A continuación, se analizan en profundidad las 4 arquitecturas base más evaluadas en la literatura para la predicción de características con un componente espacial como lo son de propiedades del suelo, desglosando sus mecanismos operativos, ventajas y limitaciones en el contexto de la estimación de características que asociados al componente espacial como el SOC.

2.1 Graph Convolutional Networks (GCN)

Las GCN como parte de las GNN se han establecido como la arquitectura fundacional en el aprendizaje profundo geométrico, actuando como una aproximación de primer orden de la convolución espectral en grafos (Dong et al., 2021). Su mecanismo central se basa en una regla de propagación por capas que agrega las características de los vecinos inmediatos, normalizadas por la matriz de grados del nodo, lo que matemáticamente equivale a aplicar un filtro de suavizado sobre la estructura del grafo (Zhu et al., 2021).

- **Ventajas:**

- La GCN es computacionalmente eficiente debido a que su complejidad escala linealmente con el número de aristas en el grafo, lo que la convierte en un bloque de construcción fundamental y una línea base robusta para arquitecturas más complejas (Dong et al., 2021).
- Al actuar esencialmente como un filtro pasa-bajas fijo en el dominio espectral, la GCN es eficaz para capturar tendencias suaves y eliminar ruido de alta frecuencia en los datos de entrada (Dong et al., 2021). Esta propiedad resulta útil en variables geoespaciales que presentan una alta autocorrelación espacial global, permitiendo modelar patrones generales de distribución (Zhu et al., 2021)

- **Limitaciones:**

- En arquitecturas profundas, la aplicación repetida del operador de convolución y agregación provoca que las representaciones de características de los nodos converjan a valores indistinguibles, limitando severamente la capacidad del modelo para distinguir características locales finas (Dong et al., 2021) . En el contexto específico de la estimación de SOC, experimentos empíricos han demostrado que este mecanismo de promedio ponderado tiende a producir mapas donde la varianza espacial de los valores predichos se suaviza excesivamente, perdiendo detalles críticos de la heterogeneidad del suelo y subestimando los valores extremos (Zhao & Efremova, 2023).
- La GCN estándar es inherentemente transductiva, lo que significa que requiere la estructura completa del grafo (incluyendo los nodos de prueba) durante la fase de entrenamiento para aprender las incrustaciones (Wu et al., 2021). Esto dificulta la generalización a nuevos nodos o ubicaciones no muestreadas sin reentrenar el modelo completo, lo cual representa una desventaja significativa para tareas de predicción en áreas no observadas o la implementación de "sensores virtuales" en redes dinámicas (Wu et al., 2021)
- La GCN asume que la influencia de los vecinos es uniforme o depende únicamente de la estructura topológica del grafo (grado del nodo), lo que le impide capturar dependencias direccionales (anisotropía) o relaciones complejas no estacionarias que son comunes en procesos ambientales como la dispersión de contaminantes o la variabilidad del suelo (Yuan, 2025).

2.2 GraphSAGE (Sample and Aggregate)

GraphSAGE (Sample and Aggregate) introduce un cambio de paradigma fundamental hacia el aprendizaje inductivo en el procesamiento de grafos. A diferencia de los enfoques transductivos que optimizan incrustaciones (embeddings) discretas para cada nodo específico en un grafo fijo, GraphSAGE aprende funciones de agregación diferenciables que pueden generalizar a nodos no vistos previamente (Li et al., 2023). El algoritmo opera en dos pasos principales: primero, muestrea un vecindario local de tamaño fijo para cada nodo; segundo, agrega la información de características de estos vecinos utilizando funciones como mean, LSTM o pooling para generar la representación del nodo (Zeghina et al., 2024).

- **Ventajas:**

- La principal fortaleza de GraphSAGE radica en su capacidad para generar predicciones para nuevas ubicaciones de muestreo (nodos invisibles durante el entrenamiento) utilizando las funciones de agregación aprendidas, sin necesidad de reentrenar el modelo o conocer la estructura global del grafo (Wu et al., 2021). Esta propiedad es crítica para la escalabilidad en sistemas de monitoreo ambiental dinámicos, permitiendo la transferencia del modelo entrenado a nuevas estructuras de red o la implementación de "sensores virtuales" para interpolación espacial (Wu et al., 2021).
- A diferencia de la arquitectura GCN estándar que promedia las características del nodo con las de sus vecinos (lo que puede diluir la señal original), GraphSAGE frecuentemente concatena las características actuales del nodo con el vector agregado de su vecindario antes de pasarlas a través de una capa totalmente conectada (Zhao & Efremova, 2023). Este mecanismo de concatenación ayuda a preservar la identidad única e información original del nodo de muestreo, evitando el suavizado excesivo de los valores extremos de SOC y permitiendo capturar patrones complejos en la distribución del carbono (Zhao & Efremova, 2023)
- Mediante el muestreo de un conjunto de vecinos de tamaño fijo en cada capa de convolución, GraphSAGE previene la expansión rápida y exponencial de los campos receptivos a través del grafo (Zhao & Efremova, 2023). Esta restricción controlada del flujo de información mitiga significativamente el problema de sobre-suavizado (*over-smoothing*) observado en las GCN tradicionales, asegurando que las representaciones de los nodos mantengan su distintividad local a medida que la red se hace más profunda (Zhao & Efremova, 2023).

- **Limitaciones:**

- Aunque el enfoque es eficiente en memoria al no requerir la matriz de adyacencia completa, el proceso de muestreo recursivo y la agregación de vecinos en múltiples saltos (k -hops) implican una carga computacional que escala con el tamaño del vecindario muestreado y la profundidad de la red, definiendo una función de agregación AGG_k que debe ser diferenciable y eficiente para procesar los vectores de características (Zeghina et al., 2024).

2.3 Graph Attention Network (GAT)

Las Graph Attention Networks (GAT) representan una evolución significativa respecto a las arquitecturas espectrales estáticas al incorporar mecanismos de auto-atención (self-attention) para ponderar dinámicamente la importancia de cada vecino. A diferencia de GCN, que asume coeficientes de normalización fijos basados en la estructura del grafo, GAT calcula coeficientes de atención aprendidos que modulan la influencia de la información entrante de cada nodo vecino (Li et al., 2023). Matemáticamente, esto se logra calculando un coeficiente e_{ij} a través de una capa de atención (generalmente una red neuronal feed-forward seguida de una no linealidad LeakyReLU) y normalizándolos mediante una función softmax (Li et al., 2023).

- **Ventajas:**

- La principal ventaja de GAT reside en su capacidad para asignar diferentes pesos a distintos vecinos dentro del mismo vecindario espacial. Esto permite al modelo priorizar ubicaciones que son funcionalmente más relevantes para la predicción del SOC (por ejemplo, aquellas que comparten características climáticas o topográficas críticas) e ignorar vecinos ruidosos o poco correlacionados (Li et al., 2023).
- Al no depender de coeficientes fijos derivados del grado del nodo, GAT es capaz de modelar interacciones asimétricas y dependencias espaciales heterogéneas, superando la limitación de isotropía de las GCN estándar. Esto es particularmente útil en contextos donde la influencia entre puntos de muestreo no es uniforme ni bidireccional (Yuan, 2025)

- **Limitaciones:**

- En la aplicación práctica para la estimación, se puede observar que los mecanismos de atención pueden fallar al diferenciar significativamente entre vecinos si las características de entrada son muy similares localmente. En estos casos, los coeficientes de atención tienden a uniformizarse, provocando que el modelo degenera en un promedio ponderado simple. Esto resulta en mapas de predicción donde la varianza espacial se suaviza excesivamente, perdiendo detalles finos de la distribución de los datos de manera similar a una GCN (Zhao & Efremova, 2023).
- El cálculo de los coeficientes de atención para cada par de nodos conectados incrementa sustancialmente la complejidad computacional y el uso de memoria en comparación con arquitecturas más simples como GCN o GraphSAGE (Li et al., 2023). La complejidad temporal del mecanismo de auto-atención escala cuadrática o

linealmente con el número de vecinos dependiendo de la implementación, lo cual puede ser prohibitivo en grafos densos o muy grandes sin técnicas de optimización adicionales (Li et al., 2023).

2.4 Adaptive Graph Convolutional Network with Spatial Autocorrelation (ASI-GCN)

El modelo ASI-GCN representa una evolución sofisticada diseñada específicamente para abordar la escasez de datos de muestreo (*sparse sampling*) en contextos complejos, como el mapeo de contaminantes o propiedades del suelo. Esta arquitectura integra la autocorrelación espacial con el aprendizaje profundo de representación de grafos, introduciendo mecanismos duales de aprendizaje y corrección para superar las limitaciones de los métodos de interpolación tradicionales (Tao et al., 2025).

ASI-GCN emplea una estructura de aprendizaje de doble módulo que combina el aprendizaje adaptativo de características con el aprendizaje dinámico de la estructura del grafo. Se distingue por incorporar un mecanismo de corrección residual de dos etapas: primero genera una predicción base y luego modela los residuos (diferencia entre observado y predicho) para refinar la estimación final, recuperando la varianza local que suele perderse en el proceso de convolución (Tao et al., 2025).

• Ventajas:

- Gracias a su mecanismo de "paso de mensajes restringido" (*constrained message passing*) y la corrección residual, el modelo evita el suavizado excesivo de los valores extremos ("hotspots"), preservando la heterogeneidad espacial crítica y la estratificación vertical de las propiedades del suelo mejor que las GCN estándar (Tao et al., 2025).
- No depende de una matriz de adyacencia estática predefinida; utiliza máscaras dinámicas de múltiples cabezales para aprender relaciones espaciales latentes, adaptándose a patrones de variabilidad complejos (Tao et al., 2025).

• Limitaciones:

- La implementación requiere un sistema de módulos duales (aprendizaje adaptativo del grafo más el subsistema de corrección residual). Esto se traduce en una mayor complejidad de diseño, entrenamiento y ajuste de hiperparámetros en comparación con arquitecturas GCN estándar.
- Si bien demostró efectividad en un área de estudio local, la literatura señala que la relativa pequeña extensión espacial del contexto de prueba inicial podría restringir la

generalizabilidad y robustez del modelo a un nivel nacional o global sin validación adicional (Tao et al., 2025)

2.5 Comparación de arquitecturas

El análisis de la evidencia empírica reportada en la literatura reciente sobre modelos de redes neuronales con énfasis en las GNN y sus variaciones revela patrones de rendimiento consistentes que guían la selección tecnológica para este proyecto. Si bien la implementación y validación con los datos de Ecuador (2021) se realizará en una etapa posterior, la revisión bibliográfica permite anticipar las ventajas, limitaciones y aplicabilidad de las arquitecturas inductivas sobre los enfoques transductivos o espectrales básicos, este análisis final se lo muestra en la Tabla 1.

Arquitectura	Ventajas	Limitaciones	Aplicabilidad
GCN	Eficiencia computacional y simplicidad de implementación; eficaz para capturar tendencias globales suaves (Dong et al., 2021).	Pérdida crítica de varianza espacial y subestimación de valores extremos en capas profundas (Zhao & Efremova, 2023). Naturaleza transductiva (Wu et al., 2021).	Línea base para comparación; áreas con alta homogeneidad espacial donde el suavizado es aceptable.
GraphSAGE	Generaliza a nodos no vistos (escalabilidad). Preserva información local mediante concatenación, evitando el suavizado excesivo (Wu et al., 2021; Zhao & Efremova, 2023).	Costo computacional asociado al muestreo recursivo de vecinos en redes profundas (Li et al., 2023).	Mapeo de SOC a gran escala en paisajes heterogéneos; predicción en ubicaciones no muestreadas.
GAT	Ponderación adaptativa (atención) para priorizar vecinos relevantes e ignorar ruido; capacidad de modelar anisotropía (Li et al., 2023).	Alto costo de memoria/cómputo. Puede degenerar en un promedio simple (suavizado) si los coeficientes de atención son uniformes (Zhao & Efremova, 2023).	Análisis donde la influencia entre puntos de muestreo es altamente asimétrica o dependiente de covariables complejas.
ASI-GCN	Robustez ante datos dispersos (sparse data) gracias a la	Mayor complejidad de la arquitectura/modelo	Mapeo de propiedades del suelo utilizando

Unidad de Gestión de Investigación y Proyección Social

Edificio 3, Primer piso

Av. Ladrón de Guevara E11-253 y Andalucía

Teléfono: 2976300 Ext. 1066

	corrección residual y aprendizaje dinámico de grafos; captura variabilidad vertical (Tao et al., 2025).	(requiere módulos duales de aprendizaje y corrección) frente a modelos estándar (Tao et al., 2025).	datos de características.
--	---	---	---------------------------

Tabla 1: Tabla comparativa de arquitecturas

En el estudio de referencia realizado por Zhao y Efremova (2023), se contrastaron directamente los operadores GCN, GraphSAGE, Transformer y GAT integrados dentro de un marco de codificación posicional (PE-GNN) utilizando la base de datos armonizada LUCAS. Los resultados cuantitativos demostraron que el modelo PESAGE (GraphSAGE + Positional Encoder) superó consistentemente a las arquitecturas PEGCN y PEGAT en métricas de error (MAE y MAPE).

El análisis comparativo del comportamiento de estos modelos destaca diferencias críticas en el manejo de la varianza espacial:

- **Limitaciones de GCN y GAT (Suavizado):** Como se resume en la Tabla 1, arquitecturas como GCN y GAT tienden a producir un efecto de suavizado excesivo (over-smoothing) en la varianza espacial de los valores predichos. Esto ocurre porque GCN opera mediante un promedio ponderado simple, y GAT, aunque utiliza atención, puede degenerar en un comportamiento de promediado si las puntuaciones de atención no varían significativamente entre vecinos. El resultado práctico es la pérdida de detalles finos y la subestimación de valores extremos ("picos" de concentración).
- **Superioridad de GraphSAGE:** Por el contrario, GraphSAGE demostró una mayor capacidad para capturar la heterogeneidad espacial y patrones complejos en los diferentes casos de estudio. Su ventaja técnica radica en el mecanismo de agregación que, a menudo, concatena las características del nodo actual con las agregadas de sus vecinos en lugar de promediarlas, preservando así la identidad original y la información local del nodo de muestreo (ver Tabla 1).

Adicionalmente, la literatura sobre mapeo de contaminantes del suelo refuerza la necesidad de mecanismos que eviten el suavizado. Tao et al. (2025) demostraron que variantes avanzadas como ASI-GCN (GCN adaptativa con corrección residual) superan drásticamente a métodos clásicos, reduciendo el RMSE hasta un 36.56% frente al Kriging Bayesiano y un 58.8% en coeficiente de correlación (R) frente a la Ponderación de Distancia Inversa (IDW) en escenarios de datos escasos.

Por lo tanto, las arquitecturas de grafos básicas (como la GCN estándar) resultan insuficientes por sí solas para la complejidad de los datos debido a su tendencia al suavizado. La evidencia favorece a GraphSAGE como la arquitectura base más prometedora para nuestra implementación futura, debido a su equilibrio entre capacidad inductiva y

preservación de la varianza local mediante concatenación, características esenciales para modelar la alta heterogeneidad espacial del SOC en el territorio ecuatoriano.

3. Diseño de modelos/arquitecturas

A continuación, se detalla la especificación técnica para la implementación de las cuatro arquitecturas GNN evaluadas. Este diseño permitirá realizar una comparativa empírica rigurosa sobre el conjunto de datos.

3.1 Arquitectura 1: Graph Convolutional Network (GCN)

Esta arquitectura servirá como línea base (baseline) para evaluar el desempeño de los modelos más avanzados. Se implementará siguiendo la formulación espectral estándar pero adaptada para regresión, la especificación del diseño de la arquitectura a mayor detalle se encuentra en la Tabla 2.

Definición del Grafo:

- **Nodos:** Puntos de muestreo estáticos.
- **Aristas:** Se construye un grafo estático basado en un umbral de distancia geográfica (δ) o k-NN fijo pre-calculado antes del entrenamiento. La matriz de adyacencia (A) se normaliza simétricamente ($D^{-\frac{1}{2}}AD^{-\frac{1}{2}}$) para evitar la explosión de gradientes (Li et al., 2023)
- **Mecanismo:** Propagación de capa completa (Full-batch), donde se actualizan todos los nodos simultáneamente utilizando la matriz Laplaciana normalizada.

Aspecto	Especificación
Número de capas	2 (Profundidades mayores causan <i>over-smoothing</i> severo) (Dong et al., 2021)
Función de activación	ReLU (Capas ocultas), Lineal (Salida)
Normalización	Matriz Laplaciana Normalizada Simétrica
Operador	Aproximación de Chebyshev de primer orden
Estrategia de Entrenamiento	Transductiva (Grafo completo en memoria)
Optimizador	Adam (Learning rate ≈ 0.01) (Zhao & Efremova, 2023)



Métricas	Error medio absoluto (MAE) Raíz del error cuadrático medio (RMSE) Coeficiente de determinación (R^2)
----------	--

Tabla 2: Diseño de Arquitectura 1

3.2 Arquitectura 2: GraphSAGE (Configuración PESAGE)

Esta es la arquitectura recomendada principal. Se centra en la capacidad inductiva y la preservación de la varianza local mediante concatenación, la especificación del diseño de la arquitectura a mayor detalle se encuentra en la Tabla 3.

Definición del Grafo:

- **Nodos:** Puntos de muestreo con vectores de características aumentados por **Codificadores Posicionales (PE)** para inyectar contexto espacial explícito.
- **Aristas:** Grafo dinámico construido por lotes (*mini-batch*) utilizando k -NN ($k \approx 5-10$) basado en coordenadas geográficas. Esto permite aprender relaciones espaciales locales cambiantes (Zhao & Efremova, 2023)
- **Mecanismo:** Muestreo de vecinos y agregación mediante la función mean, seguida de concatenación con el estado actual del nodo.

Aspecto	Especificación
Número de capas	2 a 3 (Zhao & Efremova, 2023)
Función de activación	ReLU
Agregador	Mean Aggregator (con concatenación $W_1 x_i + W_2 \cdot agg$) (Li et al., 2023)
Tamaño del batch	64 / 128 (Muestreo aleatorio)
Función de Pérdida	MSE + λ (Índice de Moran Local) para forzar coherencia espacial
Optimizador	Adam (Learning rate $\approx 1 \times 10^{-3}$)
Regularización	Dropout (0.3 - 0.5) (Zhao & Efremova, 2023)

Tabla 3: Diseño de Arquitectura 2

3.3 Arquitectura 3: Graph Attention Network (GAT)

Diseñada para evaluar si la ponderación anisotrópica (direccional/importancia variable) mejora la predicción en zonas de alta variabilidad climática, la especificación del diseño de la arquitectura a mayor detalle se encuentra en la Tabla 4.

Definición del Grafo:

- **Nodos:** Puntos de muestreo.
- **Aristas:** Conectividad definida por k –NN. A diferencia de GCN, las aristas no son fijas en peso; el modelo aprende un coeficiente de atención α_{ij} para cada par conectado.
- **Mecanismo:** Sistema dual. (1) GCN adaptativa para predicción base. (2) Corrección residual para modelar la diferencia entre la predicción y el valor real, recuperando picos de concentración perdidos (Tao et al., 2025)

Aspecto	Especificación
Número de capas	2 (Li et al., 2023)
Cabezales de Atención	Multi-head attention (4 a 8 cabezales recomendados)
Función de activación	LeakyReLU (para coeficientes de atención), ELU (salida de capas) (Li et al., 2023)
Normalización	Softmax (sobre los vecinos)
Regularización	Dropout (Crítico para evitar sobreajuste en los pesos de atención)
Optimizador	Adam (Learning rate $\approx 5 \times 10^{-4}$)
Métricas	MAE, RMSE (Sensible al costo computacional)

Tabla 4: Diseño de Arquitectura 3

3.4 Arquitectura 4: ASI-GCN (Adaptive Spatial GCN)

Arquitectura avanzada específica para escenarios de datos dispersos (sparse data), útil para validar la robustez en zonas de con menor densidad de muestreo (ej. Amazonía), la especificación del diseño de la arquitectura a mayor detalle se encuentra en la Tabla 5.

Definición del Grafo:

- **Nodos:** Puntos de muestreo estratificados.

- **Aristas:** No utiliza una matriz fija. Emplea Aprendizaje de Estructura de Grafo Dinámico, generando máscaras dinámicas (M^k) para aprender relaciones latentes entre nodos que no son necesariamente vecinos geográficos inmediatos (Tao et al., 2025).
- **Mecanismo:** Cálculo de coeficientes de atención mediante una red *feed-forward* y función Softmax sobre los vecinos. Se puede integrar codificación direccional si se dispone de datos de flujo (agua/viento) (Yuan, 2025).

Aspecto	Especificación
Número de capas	2 capas en el módulo principal + Módulo residual (Tao et al., 2025)
Mecanismo Especial	Corrección Residual de dos etapas (Prediction + Residual learning)
Función de activación	ELU (para máscaras dinámicas), Softmax (salida) (Tao et al., 2025)
Construcción de Grafo	Matriz de adyacencia enmascarada (Masked Adjacency) para evitar fuga de información de validación
Optimizador	Adam (Learning rate $\approx 5 \times 10^{-4}$)
Métricas	Reducción de RMSE y mejora en Índice de Moran (Autocorrelación)

Tabla 5: Diseño de Arquitectura 4

El análisis comparativo del diseño de arquitecturas/modelos, detallado en la Tabla 6, confirma que, si bien ASI-GCN ofrece mecanismos teóricos potentes para la corrección de errores, su complejidad de implementación es elevada. Por el contrario, GraphSAGE (en su configuración PESAGE) presenta el equilibrio técnico óptimo para este proyecto: ofrece la capacidad inductiva necesaria para escalar el modelo a nivel nacional en Ecuador, mitiga eficazmente el problema de over-smoothing mediante su mecanismo de concatenación (preservando los valores extremos críticos para el análisis) y mantiene una complejidad computacional manejable en comparación con GAT o ASI-GCN. Por tanto, se procede con la implementación de PESAGE como la arquitectura central, integrando Codificadores Posicionales para maximizar la precisión espacial.

Aspecto	GCN	GraphSAGE (PESAGE)	GAT	ASI-GCN
Mecanismo Espacial	Agregación estática basada en la matriz Laplaciana normalizada (promedio ponderado por grado) (Dong et al., 2021)	Muestreo de vecindarios de tamaño fijo y agregación mediante funciones diferenciables (<i>mean/max</i>) (Li et al., 2023)	Ponderación dinámica mediante coeficientes de atención (<i>self-attention</i>) aprendibles (Li et al., 2023)	Aprendizaje de estructura de grafo dinámico con máscaras y corrección residual de dos etapas (Tao et al., 2025).
Capacidad Inductiva	Baja (Transductiva): Requiere el grafo completo durante el entrenamiento; difícil generalizar a nodos nuevos (Wu et al., 2021).	Alta: Aprende funciones de agregación transferibles a nodos no vistos, ideal para grandes áreas (Wu et al., 2021)	Alta: El mecanismo de atención puede aplicarse a nodos nuevos, aunque suele ser más costoso.	Alta: Diseñado específicamente para inferir en zonas con datos dispersos o no muestreados.

Preservación de Varianza	Baja: Tiende al <i>over-smoothing</i> (suavizado excesivo) en capas profundas, perdiendo picos de SOC (Zhao & Efremova, 2023)	Alta: La concatenación (skip-connection) preserva la identidad del nodo central y captura heterogeneidad (Zhao & Efremova, 2023)	Media: Puede degenerar en un promedio simple si los coeficientes de atención son uniformes (Zhao & Efremova, 2023)	Alta: La corrección residual recupera explícitamente la varianza local perdida (Tao et al., 2025)
Complejidad Computacional	Baja: Escala linealmente con el número de aristas; muy eficiente (Dong et al., 2021).	Moderada: Controlada por el tamaño del muestreo de vecinos; eficiente en memoria (Li et al., 2023)	Alta: Escala cuadráticamente con el número de vecinos debido al cálculo de pares de atención (Li et al., 2023).	Alta: Requiere entrenar módulos duales (estructura + residuos), aumentando el costo (Tao et al., 2025)

Tabla 6: Comparación de Diseños

4. Resultados esperados

A partir de la revisión de literatura y del enfoque metodológico planteado, se anticipa que la integración de arquitecturas basadas en redes neuronales de grafos, particularmente variantes como GraphSAGE (PESAGE) que permiten modelar de manera más adecuada la complejidad espacial de los datos. Se espera que estas arquitecturas demuestren un comportamiento robusto ante estructuras espaciales irregulares y distribuciones de muestreo heterogéneas, características comunes en datos edáficos. A continuación, se enmarcan los diferentes resultados esperados de la aplicación de estas arquitecturas con los datos disponibles del SOC para Ecuador del 2021.

4.1 Desempeño predictivo esperado

Con base en los avances documentados en la literatura, se prevé que los modelos derivados de GraphSAGE presenten mejoras respecto a los métodos de referencia tradicionalmente utilizados en estudios de suelos, especialmente en su capacidad de capturar relaciones no lineales y dependencias espaciales complejas. Si bien aún no se han implementado los modelos propuestos, se espera que estos enfoques permitan generar predicciones más estables y generalizables, incluso en zonas con baja densidad de muestreo.

4.2 Coherencia espacial de las predicciones

Un resultado esperado clave se relaciona con la preservación de patrones espaciales en los mapas estimados de SOC. Dado que las variantes tipo PESAGE mitigan el *over-smoothing* observado en otras arquitecturas de grafos, se proyecta que las predicciones resulten más coherentes con la variabilidad real, manteniendo detalles finos y zonas extremas que suelen perderse en métodos más simplificados. La validación de esta coherencia espacial se realizará mediante métricas de autocorrelación como el Índice de Moran, herramienta ampliamente utilizada para evaluar la estructura espacial en estudios.

4.3 Potencial contribución a la gestión del suelo

Finalmente, se espera que la metodología propuesta genere insumos relevantes para la gestión y planificación del recurso suelo en Ecuador. La capacidad inductiva de los modelos basados en GraphSAGE podría facilitar la extrapolación de predicciones hacia áreas no muestreadas o de difícil acceso, fortaleciendo los procesos de monitoreo e inventario de carbono. Esto proporcionará una base técnica sólida para la toma de decisiones en contextos agrícolas, ambientales y de manejo sostenible del territorio.

5. Conclusiones

La revisión exhaustiva de la literatura y el análisis comparativo de arquitecturas de Redes Neuronales de Grafos (GNN) permiten concluir que los enfoques inductivos, especialmente aquellos basados en GraphSAGE e integrados con codificadores posicionales, representan una alternativa metodológica altamente prometedora para la estimación espacial del Carbono Orgánico del Suelo (SOC) en Ecuador. A diferencia de los métodos geoestadísticos tradicionales y de las arquitecturas transductivas como GCN, estos modelos ofrecen una mayor capacidad para capturar relaciones no lineales, preservar la heterogeneidad espacial y generalizar hacia zonas no muestreadas.

Se evidencia que las limitaciones de suavizado excesivo (*over-smoothing*), presentes en modelos como GCN y observadas ocasionalmente en GAT, pueden ser mitigadas de manera efectiva mediante mecanismos de concatenación y muestreo controlado propios de GraphSAGE. Esta característica es especialmente relevante en contextos donde la identificación de áreas con valores extremos y la preservación de patrones locales resulta crítica para el análisis y la toma de decisiones.

Asimismo, la comparación metodológica muestra que modelos más complejos, como ASI-GCN, incorporan mecanismos de corrección residual que podrían resultar útiles en escenarios de datos altamente dispersos. Sin embargo, su complejidad computacional y estructural los convierte en alternativas menos eficientes para implementaciones iniciales a escala nacional, donde la reproducibilidad y la escalabilidad son factores determinantes.

En conjunto, los hallazgos del marco teórico justifican la selección de la arquitectura PESAGE (GraphSAGE + Positional Encoding) como núcleo del diseño metodológico del proyecto. Esta elección equilibra de forma adecuada precisión, preservación de variabilidad espacial, capacidad inductiva y viabilidad computacional.

Finalmente, las expectativas metodológicas establecen una base sólida para la etapa de implementación. Los modelos derivados de GraphSAGE tienen el potencial de generar insumos estratégicos para la gestión del suelo en Ecuador, particularmente en el monitoreo del carbono, la planificación territorial y la identificación de áreas vulnerables o prioritarias. La presente investigación sienta, por tanto, un marco conceptual y técnico robusto que permitirá avanzar hacia sistemas de predicción más coherentes, escalables y ambientalmente relevantes.

6. Referencias bibliográficas

Appleby, G., Liu, L., & Liu, L. (2023). Kriging Convolutional Networks. arXiv preprint arXiv:2306.09463. <https://arxiv.org/abs/2306.09463>

Dong, Y., Ding, K., Jalaian, B., Ji, S., & Li, J. (2021). AdaGNN: Graph Neural Networks with Adaptive Frequency Response Filter. arXiv preprint arXiv:2104.12840. <https://arxiv.org/abs/2104.12840>

Li, Y., Yu, D., Liu, Z., Zhang, M., Gong, X., & Zhao, L. (2023). Graph neural network for spatiotemporal data: Methods and applications. arXiv preprint arXiv:2306.00012. <https://arxiv.org/abs/2306.00012>

McBratney, A. B., Santos, M. M., & Minasny, B. (2003). On digital soil mapping. *Geoderma*, 117(1–2), 3–52. [https://doi.org/10.1016/S0016-7061\(03\)00223-4](https://doi.org/10.1016/S0016-7061(03)00223-4)

Padarian, J., Minasny, B., & McBratney, A. B. (2019). Using deep learning for digital soil mapping. *SOIL*, 5(1), 79–89. <https://doi.org/10.5194/soil-5-79-2019>

Soliz Villafuerte, M. X., & Donoso Vargas, D. A. (2025). Informe de Preprocesamiento de Datos (Producto 2 del Proyecto PIS-24-09: Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales). Escuela Politécnica Nacional.

Tao, H., Li, Z., Nie, S., Li, H., & Zhao, D. (2025). An adaptive graph convolutional network with spatial autocorrelation for enhancing 3D soil pollutant mapping precision from sparse

borehole data. *Land*, 14(7), 1348. <https://doi.org/10.3390/land14071348>

Wadoux, A. M. J.-C., Minasny, B., & McBratney, A. B. (2020). Machine learning for digital soil mapping: Applications, challenges and suggested solutions. *Earth-Science Reviews*, 210, 103359. <https://doi.org/10.1016/j.earscirev.2020.103359>

Wu, Y., Zhuang, D., Labbe, A., & Sun, L. (2021). Inductive graph neural networks for spatiotemporal kriging. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(4), 4478–4485.

Yuan, D. (2025). Spatially directional dual-attention GAT for spatial fluoride health risk modeling. *arXiv preprint arXiv:2504.09416*. <https://arxiv.org/abs/2504.09416>

Zeghina, A., Leborgne, A., Le Ber, F., & Vacavant, A. (2024). Deep learning on spatiotemporal graphs: A systematic review, methodological landscape, and research opportunities. *Neurocomputing*, 594, 127861. <https://doi.org/10.1016/j.neucom.2024.127861>

Zhao, W., & Efremova, N. (2023). Soil organic carbon estimation from climate-related features with graph neural network. *arXiv preprint arXiv:2311.15979*. <https://arxiv.org/abs/2311.15979>

Zhu, D., Liu, Y., Yao, X., & Fischer, M. M. (2021). Spatial regression graph convolutional neural networks: A deep learning paradigm for spatial multivariate distributions. *GeoInformatica*, 25, 873–910. <https://doi.org/10.1007/s10707-021-00454-x>



Elaborado por:
Nombre: Mateo Xavier Soliz Villafuerte
Servidor Público 5

Aprobado por:
Nombre: David Andrés Donoso Vargas
Director del Proyecto PIS-24-09