

Informe sobre la Capacidad de los Modelos para Capturar la Dinámica de los Niveles de Carbono Orgánico en los Suelos de Ecuador.

Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales

Director del proyecto: David Andrés Donoso Vargas

Servidor Público 5: Mateo Xavier Soliz Villafuerte

Fecha de entrega: 04 de abril de 2026

Tabla de contenido

1.Introducción	3	
2.Objetivos		5
3.Datos y variables		6
4.Metodología		10
5.Resultados		13
6.Discusión		27
7.Conclusiones		30
6.Bibliografía		33
7.Anexos		34

1. Introducción

El presente informe analiza la capacidad de distintos modelos de aprendizaje para capturar la dinámica de los niveles de Carbono Orgánico del Suelo (SOC, por sus siglas en inglés) en Ecuador, utilizando información georreferenciada correspondiente al año 2021. El estudio se enmarca en las metodologías de mapeo digital de suelos (Digital Soil Mapping, DSM), cuyo objetivo es estimar propiedades edáficas a partir de observaciones puntuales y variables ambientales auxiliares de cobertura continua. En este contexto, la predicción del SOC constituye una tarea de alta relevancia debido a su relación con la fertilidad del suelo, la dinámica de nutrientes, la retención de humedad, el almacenamiento de carbono y la sostenibilidad de los ecosistemas terrestres.

El propósito central de este trabajo es evaluar el desempeño de diferentes modelos predictivos aplicados a la estimación del SOC, integrando muestras de suelo obtenidas in situ con variables ambientales y geospaciales derivadas de sensores remotos, datos climáticos y atributos topográficos. Este enfoque permite aprovechar la complementariedad entre mediciones directas del suelo y covariables de cobertura continua, facilitando la construcción de modelos capaces de representar la variabilidad espacial del SOC tanto a escala nacional como en contextos regionales específicos.

En el marco de este estudio se comparan cuatro modelos de predicción: GraphSAGE (Graph Sample and Aggregate), GATv2 (Graph Attention Network versión 2), Random Forest (Bosque Aleatorio) y Extra Trees (Extremely Randomized Trees, es decir, Árboles Extremadamente Aleatorizados). Los modelos GraphSAGE y GATv2 corresponden a arquitecturas basadas en Redes Neuronales de Grafos (GNN, Graph Neural Networks, por sus siglas en inglés), diseñadas para incorporar explícitamente las relaciones espaciales entre observaciones mediante estructuras de grafo. Por su parte, Random Forest y Extra Trees se emplean como modelos baseline basados en árboles de decisión, ampliamente utilizados en problemas de regresión ambiental debido a su robustez y capacidad para modelar relaciones no lineales entre variables predictoras y la variable objetivo.

La inclusión de estos modelos responde a la necesidad de analizar hasta qué punto la estructura espacial del problema aporta información relevante para la predicción del SOC. A diferencia de los enfoques tabulares convencionales, los modelos basados en grafos permiten representar interacciones entre puntos de muestreo cercanos, lo cual resulta especialmente pertinente en estudios edáficos, donde la proximidad geográfica puede

estar asociada a condiciones ambientales similares y, por tanto, a patrones espaciales de dependencia en la distribución del carbono orgánico del suelo. En este sentido, la comparación entre modelos GNN y modelos baseline permite evaluar si la incorporación explícita de relaciones espaciales mejora la capacidad predictiva del sistema de modelado.

Adicionalmente, el estudio considera dos esquemas experimentales fundamentales: el enfoque inductivo y el enfoque transductivo. En el esquema inductivo, los modelos son entrenados y evaluados sobre subconjuntos separados, lo que permite analizar su capacidad de generalización hacia observaciones no vistas durante el entrenamiento. En el esquema transductivo, en cambio, se aprovecha la estructura relacional global del grafo durante el aprendizaje, manteniendo la diferenciación entre muestras de entrenamiento y prueba, pero utilizando la conectividad espacial del conjunto de datos. La comparación entre ambos enfoques permite examinar de forma más rigurosa el papel de la estructura espacial en la estimación del SOC.

El protocolo experimental se diseñó para comparar de manera sistemática el comportamiento de los modelos bajo ambos esquemas. Para ello, se aplicó un procedimiento iterativo de partición de datos en entrenamiento y prueba, acompañado por etapas de preprocesamiento, normalización o estandarización, optimización de hiperparámetros y selección del mejor modelo antes de la evaluación final. El desempeño se analizó mediante métricas de regresión como el coeficiente de determinación (R^2), el error absoluto medio (MAE) y el error porcentual absoluto medio (MAPE), complementadas con gráficos comparativos, mapas predictivos y análisis espacial de errores.

El análisis se desarrolla para el conjunto general de muestras de SOC de Ecuador correspondientes al año 2021, y posteriormente se extiende a subconjuntos regionales específicos, particularmente las regiones Sierra y Costa. Esta estructura permite examinar si el comportamiento de los modelos se mantiene de forma consistente a distintas escalas de análisis o si presenta variaciones asociadas a la heterogeneidad ambiental y espacial de cada región.

Finalmente, el informe incorpora una sección de análisis del impacto técnico de cada metodología, con el objetivo de discutir sus fortalezas, limitaciones y eficiencia relativa dentro del proceso de modelado. En particular, se busca determinar en qué medida los modelos basados en grafos ofrecen ventajas frente a los modelos baseline y si dichas ventajas justifican su complejidad metodológica en aplicaciones de mapeo digital de suelos. En conjunto, este trabajo aporta una evaluación comparativa del potencial de estas

técnicas para la estimación del carbono orgánico del suelo en Ecuador, con implicaciones relevantes para el monitoreo ambiental, la gestión territorial y la planificación sostenible del recurso suelo.

2. Objetivos

2.1. Objetivo general

Evaluar la capacidad de los modelos GraphSAGE, GATv2, Random Forest y Extra Trees para capturar la dinámica de los niveles de carbono orgánico del suelo (SOC) en Ecuador, mediante su implementación y comparación bajo esquemas experimentales inductivo y transductivo, con base en variables ambientales y geoespaciales asociadas a las muestras de suelo.

2.2. Objetivos específicos

- Construir una base metodológica de modelado del SOC a partir de muestras georreferenciadas de suelo y variables ambientales derivadas de sensores remotos, topografía y clima, para el territorio ecuatoriano en 2021.
- Implementar en Python modelos de predicción basados en aprendizaje sobre grafos, específicamente GraphSAGE y GATv2, orientados a problemas de regresión sobre nodos espaciales, con el fin de representar explícitamente la estructura espacial entre observaciones.
- Implementar y utilizar modelos baseline tabulares, particularmente Random Forest y Extra Trees, como referencia para comparar el desempeño de los enfoques basados en grafos.
- Comparar el comportamiento de los modelos bajo los esquemas inductivo y transductivo, con el propósito de analizar su capacidad de generalización y el aporte de la estructura espacial en la predicción del SOC
- Evaluar el desempeño predictivo de los modelos mediante métricas de regresión, gráficos comparativos, mapas de predicción y análisis espacial del error, tanto para el conjunto general de Ecuador como para los subconjuntos regionales de Sierra y Costa.
- Analizar críticamente el impacto técnico de cada metodología, con el fin de determinar en qué medida los modelos basados en grafos aportan ventajas frente a los modelos

baseline en aplicaciones de mapeo digital de suelos.

3. Datos y variables

El presente estudio se desarrolló a partir de una base de datos georreferenciada de carbono orgánico del suelo correspondiente a Ecuador para el año 2021. La información alfanumérica fue organizada en un archivo tabular en formato XLSX (Excel Open XML Spreadsheet), mientras que la representación espacial de los puntos de muestreo se manejó mediante capas vectoriales en formato SHP (Shapefile) y GPKG (GeoPackage), proyectadas en el sistema UTM (Universal Transverse Mercator), zona 17. Esta organización permitió integrar de manera coherente las observaciones edáficas de campo con un conjunto amplio de covariables ambientales de carácter espacial.

La variable objetivo del estudio correspondió al contenido de carbono orgánico del suelo registrado en la base de datos. A partir de esta variable y de las covariables asociadas a cada punto de muestreo se construyó la matriz de entrada para el modelado. En su versión original, el conjunto de datos estuvo conformado por 2990 registros y 81 columnas, incluyendo variables de identificación, atributos geométricos, coordenadas, información de profundidad del perfil, variables auxiliares derivadas del procesamiento edáfico y predictores topográficos, climáticos y espectrales. La lógica de selección de variables implementada en el flujo de trabajo permitió depurar este conjunto inicial y obtener finalmente una base de 46 variables predictoras, adecuada para la comparación entre modelos.

Las covariables ambientales utilizadas en este trabajo fueron obtenidas a partir de GEE (Google Earth Engine), mediante la generación y consulta de capas satelitales, topográficas y climáticas ajustadas a una resolución espacial de 30×30 m para el año 2021. De manera general, para las variables espectrales se trabajó con composiciones representativas basadas en valores medianos, mientras que para las variables climáticas se utilizaron valores promedio. Posteriormente, estas capas ráster fueron procesadas en QGIS (Quantum Geographic Information System) para realizar el muestreo de valores ráster sobre los puntos de muestreo de suelo, es decir, la extracción del valor de cada covariable ambiental en la localización exacta de cada observación. Este procedimiento permitió asociar a cada muestra de suelo un conjunto homogéneo de atributos ambientales, el cual sirvió como base para la etapa de modelado.

Con el fin de garantizar consistencia metodológica y evitar fuga de información, se aplicó un proceso de depuración previo al entrenamiento de los modelos. En una primera etapa

se excluyeron variables de identificación, geometría, profundidad, control de calidad y atributos derivados directamente de la variable objetivo. En una segunda etapa se eliminaron aquellas covariables con más del 40 % de valores faltantes. Es importante precisar que el tratamiento de la información espacial difirió según el tipo de modelo evaluado. En los modelos basados en grafos, las coordenadas geográficas se utilizaron para construir la estructura espacial del grafo y definir relaciones de proximidad entre observaciones. En cambio, para los modelos baseline, al no incorporar explícitamente la estructura espacial, las coordenadas fueron añadidas como variables predictoras adicionales, con el propósito de que la comparación entre enfoques se realizara bajo condiciones metodológicas más equivalentes.

Las variables finalmente retenidas pueden agruparse en cinco bloques principales: topografía, Sentinel-1, Sentinel-2, Sentinel-3 y clima. La Tabla 1 resume la composición del conjunto predictor final, indicando el grupo temático, las variables incluidas, su descripción general, la fuente de información y la resolución espacial de trabajo.

Grupo	Variables	Descripción general	Fuente	Resolución de trabajo
Sentinel-1	Sentinel1_VV, Sentinel1_VH, Sentinel1_Ratio_VV_VH, Sentinel1_angle, Sentinel1_vh_vv_correcto	Variables radar asociadas a retrodispersión, relación de polarizaciones y geometría de adquisición	Google Earth Engine / Sentinel-1	30 × 30 m
Sentinel-2	Sentinel_2_B1_Aerosoles_Costeros, Sentinel_2_B2_Azul, Sentinel_2_B3_Verde, Sentinel_2_B4_Rojo	Bandas del visible y aerosoles costeros	Google Earth Engine / Sentinel-2	30 × 30 m
	Sentinel_2_B5_Red_Edge_1, Sentinel_2_B6_Red_Edge_2, Sentinel_2_B7_Red_Edge_3	Bandas red-edge relacionadas con vegetación y estado superficial	Google Earth Engine / Sentinel-2	30 × 30 m
	Sentinel_2_B8_NIR_Cercano, Sentinel_2_B8A_NIR_Estrecho	Bandas del infrarrojo cercano	Google Earth Engine / Sentinel-2	30 × 30 m
	Sentinel_2_B9_Vapor_Agua, Sentinel_2_B11_SWIR_1, Sentinel_2_B12_SWIR_2	Bandas asociadas a vapor de agua e infrarrojo de onda corta	Google Earth Engine / Sentinel-2	30 × 30 m
	Sentinel_2_AOT_Espesor_Optico_Aerosoles, Sentinel_2_WVP_Vapor_Agua_Atmosferico, Sentinel_2_SCL_Clasificacion_Escena	Variables atmosféricas y clasificación de escena	Google Earth Engine / Sentinel-2	30 × 30 m
Sentinel-3	Sentinel_3_Oa02_Radiancia, Sentinel_3_Oa03_Radiancia, Sentinel_3_Oa04_Radiancia, Sentinel_3_Oa05_Radiancia, Sentinel_3_Oa06_Radiancia, Sentinel_3_Oa07_Radiancia, Sentinel_3_Oa08_Radiancia, Sentinel_3_Oa09_Radiancia	Variables de radiancia en distintas longitudes de onda	Google Earth Engine / Sentinel-3	30 × 30 m
	Sentinel_3_Oa11_Radiancia, Sentinel_3_Oa12_Radiancia, Sentinel_3_Oa13_Absorcion_Oxigeno, Sentinel_3_Oa14_Vapor_Agua	Radiancia y variables atmosféricas vinculadas a absorción y vapor de agua	Google Earth Engine / Sentinel-3	30 × 30 m
	Sentinel_3_Oa15_Radiancia, Sentinel_3_Oa16_Radiancia, Sentinel_3_Oa17_Radiancia, Sentinel_3_Oa18_Radiancia, Sentinel_3_Oa19_Radiancia, Sentinel_3_Oa20_Radiancia, Sentinel_3_Oa21_Radiancia	Radiancia espectral complementaria	Google Earth Engine / Sentinel-3	30 × 30 m
Topografía	Aspect1, Curvature1, Elevation1, Slope1, TWI1	Variables derivadas del relieve: orientación, curvatura, elevación, pendiente e índice topográfico de humedad	DEM / derivados topográficos	30 × 30 m
Clima	Temperatura_promedio, Lluvia_promedio	Variables climáticas agregadas para 2021, usadas como controles ambientales regionales	Google Earth Engine / capas climáticas	30 × 30 m*
Variable objetivo	CO ₂	Variable respuesta del modelo	INAHM/MAG	N/A
Coordenadas	lat, lon	Construcción del grafo espacial	INAHM/MAG	N/A
Región	region	Filtrado territorial (Ecuador, Sierra, Costa)	INAHM/MAG	N/A

Tabla 1. Resumen de las variables predictoras utilizadas en el modelado del carbono orgánico del suelo

La Tabla 1 muestra que el conjunto predictor final tuvo una composición ambiental diversa y complementaria. Predominaron las variables espectrales provenientes de Sentinel-2 y Sentinel-3, acompañadas por información radar de Sentinel-1, atributos topográficos y covariables climáticas. Esta estructura resulta metodológicamente adecuada para el modelado del carbono orgánico del suelo, ya que combina información de superficie, relieve y clima, es decir, factores que pueden intervenir en la acumulación, transformación y distribución espacial de la materia orgánica en el suelo. Asimismo, la tabla evidencia que la base final no se limitó a un solo tipo de dato, sino que integró múltiples fuentes con capacidad explicativa potencial para el fenómeno analizado.

De manera complementaria, la Tabla 2 resume las variables que no formaron parte del conjunto predictor final, diferenciando entre aquellas excluidas por razones estructurales o

metodológicas y aquellas eliminadas por presentar una proporción elevada de valores faltantes. Esta organización permite transparentar el criterio de depuración aplicado antes del entrenamiento de los modelos.

Tipo de tratamiento	Variables	Justificación general
Variables excluidas por estructura, metadatos o potencial fuga de información	N, Da, CO_g, SOC_stock_0_30_Mg_ha, Coord_X, Coord_Y, fid, Perfil, Lim_sup, Lim_inf, geometry, longitud, latitud, Rango_profundidad, Profundidad_cm, Rango_profundidad_normalizado, is_outlier_SOC, z_top_cm, z_bot_cm, overlap_cm, soc_w, bd_w, overlap_total_cm, SOC_wsum, BD_wsum, SOC_gkg_wmean, BD_gcm3_wmean, cobertura_0_30_pct, flag_baja_cobertura, region	Corresponden a identificadores, variables geométricas, atributos auxiliares del perfil, variables de control o variables derivadas directa o indirectamente de la variable objetivo
Variables espaciales con tratamiento diferenciado	lon, lat	En los modelos basados en grafos se utilizaron para construir la conectividad espacial; en los modelos baseline se incorporaron como variables predictoras adicionales
	Sentinel 3_Oa01_Radiancia, Sentinel 3_Oa10_Radiancia, Sentinel 3_Quality_Flags_Corrupta	Baja completitud de datos, lo que podía afectar la estabilidad del modelado

Tabla 2. Variables no incorporadas directamente al conjunto predictor final

La Tabla 2 permite observar que la exclusión de variables no respondió a una reducción arbitraria del dataset, sino a un criterio metodológico orientado a preservar únicamente información pertinente para la predicción. Por un lado, se descartaron variables cuya presencia habría introducido redundancia, fuga de información o contenido meramente descriptivo. Por otro lado, se separó el tratamiento de las coordenadas geográficas, ya que su función fue distinta según el tipo de modelo. Finalmente, la eliminación de covariables con alta proporción de datos faltantes contribuyó a garantizar una base más estable y consistente para el entrenamiento y la comparación de los modelos.

En síntesis, la base final de modelado fue el resultado de tres etapas complementarias: la obtención de covariables espaciales mediante Google Earth Engine, el muestreo de valores ráster sobre los puntos de suelo en QGIS y la depuración final del conjunto de variables conforme a criterios de pertinencia metodológica y completitud. El resultado fue una matriz predictora robusta, compuesta por variables topográficas, radar, espectrales y climáticas, adecuada para la comparación de los modelos evaluados en este estudio. En

conjunto, las Tablas 1 y 2 permiten documentar tanto la composición final del conjunto predictor como la lógica de exclusión aplicada durante la preparación de los datos.

4. Metodología

La metodología del presente estudio se estructuró como un esquema comparativo orientado a evaluar la capacidad de distintos modelos para estimar el carbono orgánico del suelo a partir de una base de datos georreferenciada compuesta por muestras de suelo y covariables ambientales derivadas de sensores remotos, topografía y clima. Sobre esta base se implementó un protocolo experimental que permitió contrastar modelos baseline y modelos basados en grafos bajo dos condiciones de aprendizaje espacial: un enfoque transductivo y un enfoque inductivo. En términos generales, el flujo metodológico comprendió la preparación de la matriz de entrada, la definición de la estructura espacial, el ajuste de modelos, la optimización de hiperparámetros y la evaluación comparativa de resultados

4.1. Enfoque transductivo e inductivo

El estudio consideró dos esquemas experimentales complementarios. En el enfoque transductivo, la estructura del grafo se construyó de manera conjunta para las observaciones de entrenamiento y prueba, manteniendo la diferenciación entre ambos subconjuntos mediante máscaras internas. Esto permitió que los modelos basados en grafos aprovecharan la conectividad espacial global del conjunto de datos durante el aprendizaje, sin perder la separación entre el ajuste y la evaluación. En el enfoque inductivo, en cambio, los grafos de entrenamiento y prueba se construyeron por separado, de modo que la evaluación se realizara sobre observaciones no vistas durante el entrenamiento. Esta formulación permitió contrastar un escenario en el que la estructura espacial global está disponible durante el aprendizaje con otro en el que la generalización hacia subconjuntos independientes es metodológicamente más exigente.

En ambos enfoques, la conectividad espacial se definió mediante un esquema de k vecinos más cercanos, calculado a partir de la distancia de Haversine sobre las coordenadas geográficas de los puntos de muestreo. En el caso transductivo, esta conectividad se calculó sobre el conjunto combinado de entrenamiento y prueba; en el caso inductivo, se construyó de forma independiente para cada subconjunto. Esta decisión metodológica

permitió representar explícitamente relaciones de proximidad entre observaciones geográficamente cercanas, aspecto fundamental para la implementación de las arquitecturas basadas en Redes Neuronales de Grafos.

4.2. Modelos evaluados

Se evaluaron cuatro modelos de predicción. Como enfoques basados en grafos se utilizaron GraphSAGE (Graph Sample and Aggregate) y GATv2 (Graph Attention Network v2), ambas arquitecturas orientadas a tareas de regresión sobre nodos espaciales. GraphSAGE genera representaciones de cada observación a partir de la agregación de información proveniente de sus vecinos, mientras que GATv2 incorpora mecanismos de atención que asignan pesos diferenciales a dichas relaciones espaciales. Estas arquitecturas fueron seleccionadas por su capacidad para incorporar explícitamente la dependencia espacial entre puntos de muestreo.

Como modelos de referencia se utilizaron Random Forest y Extra Trees, considerados modelos baseline basados en árboles de decisión. Su inclusión permitió disponer de una línea base de comparación frente a los enfoques GNN. Dado que estos modelos no representan de forma explícita la estructura espacial mediante grafos, las coordenadas geográficas fueron incorporadas como variables predictoras adicionales en la matriz de entrada de los modelos baseline, con el propósito de que dispusieran también de información locacional y que la comparación con GraphSAGE y GATv2 se realizara bajo condiciones más equilibradas. De este modo, mientras los modelos basados en grafos aprovecharon la dimensión espacial a través de la conectividad relacional, los modelos baseline la incorporaron mediante la inclusión directa de las coordenadas en el conjunto predictor.

Adicionalmente, en la implementación presentada los modelos de árboles se utilizaron también como soporte para la construcción de una representación enriquecida de entrada en las arquitecturas GNN, mediante predicciones auxiliares generadas bajo un esquema out-of-fold. Esta estrategia permitió incorporar una tendencia base tabular al proceso de aprendizaje de GraphSAGE y GATv2, integrando simultáneamente información ambiental tabular y estructura relacional espacial.

4.3 Estrategia de comparación

La comparación entre modelos se realizó mediante un diseño de múltiples particiones repetidas del conjunto de datos. En la implementación mostrada, por ejemplo para el análisis regional de la Costa, se empleó una partición de 70 % para entrenamiento y 30 %

para prueba (`test_size = 0.3`) y se ejecutaron cinco repeticiones del experimento (`n_splits_repeats = 5`), correspondientes a semillas sucesivas de partición. Este diseño permitió reducir la dependencia de los resultados respecto de una sola división del conjunto de datos y obtener medidas promedio de desempeño más estables para cada modelo.

En cada repetición se siguió un flujo común de trabajo. En primer lugar, se aplicaron procedimientos de imputación y escalado de variables. Posteriormente, se ajustaron los modelos baseline y se generaron predicciones auxiliares out-of-fold, que fueron incorporadas a la matriz de entrada ampliada utilizada por las arquitecturas basadas en grafos. A continuación, se llevó a cabo una etapa de optimización de hiperparámetros mediante Hyperopt, con 15 evaluaciones para GraphSAGE (`max_evals_sage = 15`) y 15 evaluaciones para GATv2 (`max_evals_gat = 15`) en cada repetición. Finalmente, los modelos se entrenaron con una configuración base que incluyó hasta 180 épocas (`epochs = 180`), un criterio de detención temprana de 30 épocas sin mejora (`patience = 30`), una función de pérdida de tipo Huber (`loss = "huber"`) con parámetro 0.8 (`huber_delta = 0.8`) y un control de recorte del gradiente de 3.0 (`grad_clip = 3.0`).

La evaluación del desempeño se realizó a partir de métricas de regresión calculadas tanto en entrenamiento como en prueba. En particular, se utilizaron el coeficiente de determinación (R^2), el error absoluto medio (MAE, Mean Absolute Error), el error porcentual absoluto medio (MAPE, Mean Absolute Percentage Error) y la raíz del error cuadrático medio (RMSE, Root Mean Squared Error). De manera complementaria, se calcularon indicadores asociados a la diferencia entre entrenamiento y prueba, con el fin de apoyar la interpretación del comportamiento de los modelos en términos de estabilidad, ajuste y generalización. Los resultados de todas las repeticiones se integraron posteriormente en tablas resumen con promedios y desviaciones estándar por modelo, lo que permitió establecer una comparación más robusta que la obtenida a partir de una única partición.

4.4 Justificación de la configuración experimental

La configuración experimental adoptada en este estudio respondió a un equilibrio entre consistencia metodológica, estabilidad del entrenamiento y disponibilidad de recursos computacionales. En particular, el número de repeticiones, el tamaño de la búsqueda de hiperparámetros y el número máximo de épocas se definieron en niveles moderados con el fin de hacer viable la ejecución completa del experimento en tiempos razonables. Esta consideración fue especialmente relevante dado que cada repetición implicó la preparación de los datos, la partición en entrenamiento y prueba, el ajuste de modelos baseline, la

generación de predicciones auxiliares, la optimización de GraphSAGE y GATv2 y la exportación de resultados finales.

Bajo esta lógica, los valores adoptados para la partición de prueba, el número de repeticiones, el número de evaluaciones de Hyperopt y la configuración base de entrenamiento no deben interpretarse como una exploración exhaustiva del espacio de búsqueda, sino como una aproximación experimental de alcance controlado, adecuada para esta etapa del trabajo. El objetivo principal fue disponer de una configuración suficientemente estable para realizar una comparación metodológica consistente entre modelos y entre esquemas de aprendizaje, más que agotar todas las combinaciones posibles de hiperparámetros o de duración del entrenamiento.

En este sentido, es importante reconocer que la configuración empleada fue relativamente conservadora y estuvo condicionada por limitaciones prácticas de tiempo de ejecución y capacidad de cómputo. En futuras etapas del trabajo, particularmente en una versión orientada a publicación científica, será conveniente disponer de mayores recursos computacionales para ampliar el número de iteraciones experimentales, incrementar el tamaño del espacio de búsqueda de hiperparámetros y explorar configuraciones de entrenamiento más extensas. Esto permitiría aumentar el número de evaluaciones de Hyperopt, expandir el número máximo de épocas, considerar un mayor número de repeticiones del experimento y, en consecuencia, fortalecer la robustez estadística de los resultados y reducir la sensibilidad a configuraciones puntuales de entrenamiento.

En conjunto, la metodología adoptada permitió comparar de manera homogénea el comportamiento de los modelos baseline y de las arquitecturas basadas en grafos bajo dos esquemas de aprendizaje distintos. Esta estructura experimental proporcionó un marco adecuado para analizar tanto la capacidad predictiva de cada modelo como el aporte específico de la estructura espacial en la estimación del carbono orgánico del suelo, al tiempo que dejó explícitas las restricciones operativas bajo las cuales se desarrolló la presente etapa del estudio.

5. Resultados

En esta sección se presentan los resultados obtenidos en la predicción del carbono orgánico del suelo mediante los modelos GraphSAGE (Graph Sample and Aggregate), GATv2 (Graph Attention Network v2), Random Forest y Extra Trees, evaluados bajo los esquemas metodológicos descritos previamente. El análisis se organiza en tres niveles

espaciales: el conjunto nacional de muestras correspondiente a Ecuador, y los subconjuntos regionales de Sierra y Costa. En cada caso, la comparación se apoya en métricas de desempeño, gráficos de valores observados frente a valores predichos y representaciones espaciales de las predicciones y del error, con el fin de examinar tanto la precisión numérica como la consistencia espacial de los modelos.

5.1 Resultados de los modelos a nivel Ecuador

En esta sección se presentan los resultados obtenidos para el conjunto completo de muestras de carbono orgánico del suelo de Ecuador correspondientes al año 2021. El análisis a escala nacional permite evaluar el comportamiento de los modelos bajo un escenario de mayor heterogeneidad ambiental y espacial, integrando observaciones distribuidas en distintas condiciones topográficas, climáticas y de cobertura. En este contexto, la comparación entre modelos baseline y arquitecturas basadas en grafos resulta especialmente relevante, ya que permite examinar si la incorporación explícita de relaciones espaciales aporta ventajas en la predicción del carbono orgánico del suelo..

5.1.1 Resultados de la Experimentación inductiva

La experimentación inductiva para Ecuador se ejecutó mediante cinco corridas independientes, correspondientes a distintas semillas de partición. En todas ellas se mantuvo la misma estructura general del conjunto de datos, con 2990 registros, 81 columnas originales, 32 variables excluidas por razones estructurales o de posible fuga de información, y 3 variables eliminadas por presentar más del 40 % de valores faltantes. Como resultado, en cada corrida se trabajó con un total de 46 variables predictoras. Este comportamiento constante entre repeticiones confirma que la etapa de preparación de datos fue estable y reproducible a lo largo del experimento inductivo.

Durante cada corrida se ejecutó el mismo flujo metodológico: cálculo de la tendencia base para los modelos baseline, optimización de hiperparámetros para GraphSAGE (Graph Sample and Aggregate) y GATv2 (Graph Attention Network v2), y evaluación final sobre el subconjunto de prueba. El resumen promedio de las cinco particiones permitió comparar el desempeño medio de los cuatro modelos evaluados: GraphSAGE, GATv2, Random Forest y Extra Trees.

Tabla 3. Resumen promedio de métricas en prueba para la experimentación inductiva a nivel Ecuador.

Modelo	RMSE medio	Desviación estándar RMSE	R ² medio	Desviación estándar R ²
GraphSAGE	19.6029	1.8017	0.3767	0.081
GATv2	19.8563	1.1941	0.3614	0.0286
Random Forest (Baseline)	20.1763	1.3352	0.3413	0.0195
Extra Trees (Baseline)	21.0054	1.3453	0.286	0.0167

Tabla 3. Resumen promedio de métricas en prueba para la experimentación inductiva a nivel Ecuador

La Tabla 3 muestra que, en el esquema inductivo, el mejor desempeño promedio fue alcanzado por GraphSAGE, con un RMSE medio de 19.6029 y un R² medio de 0.3767. En segundo lugar, se ubicó GATv2, con un RMSE medio de 19.8563 y un R² medio de 0.3614. Los modelos baseline presentaron un rendimiento inferior: Random Forest obtuvo un RMSE medio de 20.1763 y un R² medio de 0.3413, mientras que Extra Trees registró el menor desempeño relativo, con un RMSE medio de 21.0054 y un R² medio de 0.2860.

Desde una perspectiva comparativa, estos resultados indican que los dos modelos basados en grafos superaron a los enfoques baseline en el escenario inductivo evaluado para Ecuador. La mejora observada fue más clara en el caso de GraphSAGE, que alcanzó simultáneamente el menor error medio y el mayor coeficiente de determinación. Este comportamiento sugiere que la incorporación de relaciones espaciales entre observaciones aportó información útil para capturar parte de la variabilidad del carbono orgánico del suelo a escala nacional, incluso bajo un esquema inductivo, donde la exigencia de generalización es mayor que en el enfoque transductivo.

En términos de estabilidad entre corridas, GATv2 presentó una menor variabilidad en R² y en RMSE que GraphSAGE, lo que sugiere un comportamiento más uniforme entre particiones. Sin embargo, GraphSAGE mantuvo un mejor desempeño promedio global. Esto implica que, aunque GraphSAGE fue el modelo más preciso en promedio, GATv2 mostró una respuesta más estable frente a los cambios de partición. Por su parte, Random Forest conservó un rendimiento competitivo como baseline, aunque sin superar a los modelos GNN, mientras que Extra Trees se ubicó consistentemente como la alternativa de menor ajuste entre los cuatro modelos evaluados.

En conjunto, la experimentación inductiva a nivel Ecuador muestra una ventaja moderada de las arquitecturas basadas en grafos frente a los modelos baseline. No obstante, la magnitud de la diferencia no es extrema, por lo que su interpretación debe complementarse con el análisis gráfico de valores observados frente a predichos y con la evaluación espacial de las predicciones. En este sentido, los resultados numéricos obtenidos

constituyen una primera evidencia de que la estructura espacial incorporada por GraphSAGE y GATv2 puede contribuir positivamente a la predicción del carbono orgánico del suelo en Ecuador.

Como complemento a los resultados presentados en esta subsección, en el Anexo 1 se incluyen los mapas predictivos correspondientes al caso de Ecuador bajo el esquema inductivo, en el Anexo 2 se presentan los gráficos de error con componente espacial, y en el Anexo 3 se encuentran los gráficos comparativos entre valores observados y valores predichos. Estos materiales permiten revisar con mayor detalle la distribución espacial de las predicciones y la consistencia del ajuste alcanzado por los modelos.

5.1.2 Resultados de la Experimentación transductiva

La experimentación transductiva para el conjunto nacional de Ecuador se desarrolló bajo un esquema en el que las observaciones de entrenamiento y prueba fueron integradas en una misma estructura de grafo, manteniendo su separación mediante máscaras internas. Este planteamiento permitió a los modelos basados en grafos aprovechar la conectividad espacial global del conjunto de datos durante el aprendizaje, con el objetivo de evaluar si dicha estructura relacional mejoraba la predicción del carbono orgánico del suelo frente a los modelos baseline.

La Tabla 4 muestra que, en el esquema transductivo a nivel Ecuador, el mejor desempeño promedio en prueba fue alcanzado por GATv2, con un RMSE medio de 18.1801 y un R^2 medio de 0.4649. En segundo lugar se ubicó GraphSAGE, con un RMSE medio de 18.4261 y un R^2 medio de 0.4491. Los modelos baseline presentaron un rendimiento inferior, ya que Random Forest obtuvo un RMSE medio de 20.1763 y un R^2 medio de 0.3413, mientras que Extra Trees registró el menor ajuste, con un RMSE medio de 21.0054 y un R^2 medio de 0.2860.

Modelo	RMSE medio	Desviación estándar RMSE	R^2 medio	Desviación estándar R^2
GATv2	18.1801	1.2147	0.4649	0.0259
GraphSAGE	18.4261	0.9156	0.4491	0.0359
Random Forest	20.1763	1.3352	0.3413	0.0195
Extra Trees	21.0054	1.3453	0.286	0.0167

Tabla 4. Resumen promedio de métricas en prueba para la experimentación transductiva a nivel Ecuador

De manera complementaria, los productos gráficos asociados a esta experimentación

pueden consultarse en los anexos del informe. En el Anexo 1 se encuentran los mapas predictivos del caso de Ecuador bajo el esquema transductivo, en el Anexo 2 los gráficos de error espacial, y en el Anexo 3 los gráficos comparativos entre valores reales y valores predichos. Estos insumos permiten ampliar la interpretación de los resultados más allá de las métricas resumidas en esta sección.

Comparación entre el esquema inductivo y el esquema transductivo a Nivel de Ecuador

La comparación entre los esquemas inductivo y transductivo a nivel Ecuador permite evaluar en qué medida la incorporación de la estructura espacial global del grafo modifica el desempeño de los modelos. Mientras que en el esquema inductivo los modelos fueron evaluados sobre subconjuntos separados, en el esquema transductivo las observaciones de entrenamiento y prueba se integraron en una misma estructura relacional, manteniendo su separación mediante máscaras. Esta diferencia metodológica resulta especialmente relevante para los modelos basados en grafos, ya que determina el grado en que pueden aprovechar la conectividad espacial del conjunto de datos durante el aprendizaje.

La Tabla 5 muestra que el cambio del esquema inductivo al esquema transductivo produjo una mejora clara en los dos modelos basados en grafos. En GraphSAGE, el RMSE se redujo de 19.6029 a 18.4261, mientras que el R^2 aumentó de 0.3767 a 0.4491. En GATv2, la mejora fue aún más marcada: el RMSE descendió de 19.8563 a 18.1801, y el R^2 se incrementó de 0.3614 a 0.4649. En contraste, los modelos baseline, Random Forest y Extra Trees, mantuvieron exactamente los mismos valores promedio en ambos esquemas, sin evidenciar cambios en su desempeño.

Modelo	RMSE inductivo	RMSE transductivo	Diferencia RMSE	R^2 inductivo	R^2 transductivo	Diferencia R^2
GATv2	19.8563	18.1801	-1.6762	0.3614	0.4649	0.1035
GraphSAGE	19.6029	18.4261	-1.1768	0.3767	0.4491	0.0724
Random Forest	20.1763	20.1763	0	0.3413	0.3413	0
Extra Trees	21.0054	21.0054	0	0.286	0.286	0

Tabla 5. Comparación de métricas promedio en prueba entre el esquema inductivo y el esquema transductivo a nivel Ecuador

Este comportamiento confirma que el beneficio del esquema transductivo se concentró en los modelos diseñados para aprovechar explícitamente la estructura relacional del espacio. En el caso de Ecuador, la disponibilidad de un grafo conjunto permitió que GraphSAGE y,

sobre todo, GATv2, utilizaran de manera más efectiva la conectividad espacial entre observaciones, lo que se tradujo en una reducción del error y en una mayor capacidad explicativa. Por el contrario, los modelos baseline no mostraron diferencias entre esquemas, lo cual es coherente con su naturaleza metodológica: aunque incorporan las coordenadas como variables auxiliares, no modelan directamente relaciones de vecindad ni mecanismos de propagación de información sobre un grafo.

La comparación también modifica la jerarquía relativa de los modelos. En el esquema inductivo, GraphSAGE fue el modelo con mejor desempeño promedio, seguido de GATv2. Sin embargo, en el esquema transductivo, GATv2 pasó a ocupar la primera posición, superando ligeramente a GraphSAGE tanto en RMSE como en R^2 . Este cambio sugiere que el mecanismo de atención incorporado por GATv2 fue particularmente efectivo cuando dispuso de la estructura espacial global del conjunto de datos, permitiéndole ponderar de manera más adecuada la influencia de los nodos vecinos en la predicción del carbono orgánico del suelo.

Desde el punto de vista de la estabilidad, el esquema transductivo también mostró ventajas para los modelos GNN. En GraphSAGE, la desviación estándar del RMSE disminuyó de manera importante entre el esquema inductivo y el transductivo, al igual que la variabilidad del R^2 , lo que indica un comportamiento más consistente entre particiones. En GATv2, la variabilidad del R^2 también se redujo ligeramente, mientras que la del RMSE se mantuvo en un nivel similar. En conjunto, estos resultados sugieren que el esquema transductivo no solo mejoró la precisión promedio de los modelos basados en grafos, sino que también contribuyó a estabilizar su comportamiento experimental.

En términos metodológicos, la comparación a nivel Ecuador permite concluir que la estructura espacial global del conjunto de datos constituye una fuente de información relevante para la predicción del carbono orgánico del suelo. La mejora observada en GraphSAGE y GATv2, junto con la ausencia de cambios en Random Forest y Extra Trees, indica que el principal valor del esquema transductivo radica precisamente en potenciar a los modelos que están diseñados para explotar de forma explícita la conectividad espacial. Por ello, en el contexto nacional, el enfoque transductivo puede considerarse más favorable que el inductivo para las arquitecturas basadas en grafos, particularmente en el caso de GATv2, que presentó el mejor desempeño global en esta escala de análisis.

Para una revisión visual más detallada de las diferencias entre ambos esquemas a nivel Ecuador, se recomienda consultar los anexos del informe. En el Anexo 1 se presentan los

mapas predictivos generados para ambos enfoques, en el Anexo 2 los gráficos de error espacial, y en el Anexo 3 los gráficos comparativos de valores observados y predichos. Estos elementos permiten complementar la comparación numérica desarrollada en esta subsección.

5.2 Resultados de los modelos a nivel región Sierra

En esta subsección se presentan los resultados obtenidos para la región Sierra, con el propósito de evaluar el comportamiento de los modelos en un dominio espacial más específico que el conjunto nacional. En este caso, el análisis se realizó sobre un subconjunto de 1465 observaciones, obtenido mediante el filtrado regional de la base original. Al igual que en el caso de Ecuador, en todas las corridas se mantuvo la misma estructura general del dataset, con 81 columnas originales, 32 variables excluidas por razones estructurales o de posible fuga de información, 3 variables eliminadas por presentar más del 40 % de valores faltantes y un conjunto final de 46 variables predictoras. Este comportamiento estable a través de las repeticiones confirma la consistencia de la etapa de preparación de datos en el análisis regional de la Sierra.

La evaluación se desarrolló tanto bajo el esquema inductivo como bajo el esquema transductivo, utilizando cinco repeticiones experimentales en cada caso. Esto permitió examinar no solo el desempeño promedio de los modelos en la región, sino también comparar el efecto de la estructura espacial cuando esta se incorpora mediante grafos conjuntos o mediante grafos separados entre entrenamiento y prueba. Los resultados obtenidos muestran una tendencia clara: en ambos esquemas, las arquitecturas basadas en grafos superaron de manera consistente a los modelos baseline, lo que sugiere que la dimensión espacial resulta especialmente informativa en el contexto de la región Sierra.

5.2.1 Resultados de la Experimentación inductiva a nivel región Sierra

En el esquema inductivo, el análisis se realizó sobre grafos separados para entrenamiento y prueba, de modo que los modelos fueran evaluados en un escenario de generalización espacial más estricto. De acuerdo con los resultados proporcionados, el resumen promedio de las cinco particiones muestra que el mejor desempeño correspondió a GraphSAGE, seguido por GATv2, mientras que los modelos baseline, Random Forest y Extra Trees, presentaron valores de error más altos y coeficientes de determinación menores.

La Tabla 6 muestra que, en la región Sierra y bajo el esquema inductivo, GraphSAGE alcanzó el mejor desempeño promedio, con un RMSE medio de 21.3436 y un R^2 medio de

0.4549. En segundo lugar, se ubicó GATv2, con un RMSE medio de 21.4521 y un R^2 medio de 0.4481. Ambos modelos basados en grafos superaron claramente a los modelos baseline. En particular, Random Forest obtuvo un RMSE medio de 24.6772 y un R^2 medio de 0.2717, mientras que Extra Trees registró el menor ajuste, con un RMSE medio de 25.6845 y un R^2 medio de 0.2111.

Modelo	RMSE medio	Desviación estándar RMSE	R^2 medio	Desviación estándar R^2
GraphSAGE	21.3436	1.7364	0.4549	0.053
GATv2	21.4521	1.0297	0.4481	0.0432
Random Forest	24.6772	1.5655	0.2717	0.0355
Extra Trees	25.6845	1.6073	0.2111	0.035

Tabla 6. Resumen promedio de métricas en prueba para la experimentación inductiva en la región Sierra

Desde una perspectiva interpretativa, estos resultados sugieren que en la región Sierra la estructura espacial aporta una señal predictiva importante para la estimación del carbono orgánico del suelo. La diferencia entre los modelos GNN y los baseline es más marcada que la observada a nivel nacional, lo que podría indicar que, en este contexto regional, las relaciones de vecindad entre observaciones capturan patrones ambientales o territoriales que los modelos tabulares no logran representar con la misma eficacia. Asimismo, aunque GraphSAGE y GATv2 presentaron desempeños muy cercanos, GraphSAGE logró simultáneamente el menor error medio y el mayor coeficiente de determinación, lo que lo posiciona como el mejor modelo en esta configuración inductiva.

En términos de estabilidad, GATv2 mostró una desviación estándar menor en RMSE y R^2 , lo que sugiere un comportamiento algo más uniforme entre las distintas particiones. Sin embargo, dicha estabilidad no se tradujo en un mejor desempeño promedio que el alcanzado por GraphSAGE. En conjunto, la experimentación inductiva en la Sierra refuerza la idea de que los modelos basados en grafos ofrecen una ventaja metodológica relevante frente a los enfoques baseline cuando la tarea exige generalización hacia subconjuntos no vistos durante el entrenamiento.

Los resultados de esta subsección pueden revisarse también desde una perspectiva gráfica y espacial en los anexos correspondientes. En el Anexo 1 se incluyen los mapas predictivos de la región Sierra bajo el esquema inductivo, en el Anexo 2 los gráficos de error espacial, y en el Anexo 3 los gráficos comparativos entre valores observados y valores predichos. Estos materiales complementan la interpretación de las métricas de

desempeño presentadas en el texto.

5.2.2 Resultados de la Experimentación transductiva a nivel región Sierra

En el esquema transductivo, el análisis se realizó sobre un grafo conjunto que integró las observaciones de entrenamiento y prueba, manteniendo la separación entre ambas mediante máscaras internas. Este enfoque permitió a los modelos basados en grafos aprovechar la conectividad espacial global del conjunto de datos, lo que resulta especialmente pertinente en una región como la Sierra, donde la variabilidad del relieve y de las condiciones ambientales puede generar dependencias espaciales complejas.

La Tabla 7 muestra que, en el esquema transductivo, GraphSAGE volvió a presentar el mejor desempeño promedio, con un RMSE medio de 21.5183 y un R^2 medio de 0.4455. En segundo lugar, se ubicó GATv2, con un RMSE medio de 21.6099 y un R^2 medio de 0.4390. Al igual que en el esquema inductivo, ambos modelos GNN superaron de manera clara a Random Forest y Extra Trees, cuyos valores medios se mantuvieron considerablemente por debajo en términos de ajuste y por encima en términos de error.

Modelo	RMSE medio	Desviación estándar RMSE	R^2 medio	Desviación estándar R^2
GraphSAGE	21.5183	1.5932	0.4455	0.0527
GATv2	21.6099	0.8542	0.439	0.0518
Random Forest	24.6772	1.5655	0.2717	0.0355
Extra Trees	25.6845	1.6073	0.2111	0.035

Tabla 7. Resumen promedio de métricas en prueba para la experimentación transductiva en la región Sierra

La Tabla 5 muestra que, en el esquema transductivo, GraphSAGE volvió a presentar el mejor desempeño promedio, con un RMSE medio de 21.5183 y un R^2 medio de 0.4455. En segundo lugar, se ubicó GATv2, con un RMSE medio de 21.6099 y un R^2 medio de 0.4390. Al igual que en el esquema inductivo, ambos modelos GNN superaron de manera clara a Random Forest y Extra Trees, cuyos valores medios se mantuvieron considerablemente por debajo en términos de ajuste y por encima en términos de error.

Estos resultados confirman que, para la región Sierra, la incorporación explícita de la estructura espacial mejora la capacidad predictiva del sistema de modelado. La diferencia entre los modelos basados en grafos y los baseline continúa siendo amplia, lo que refuerza la idea de que la proximidad geográfica entre observaciones contiene información relevante para estimar el carbono orgánico del suelo en este contexto regional. Asimismo, el hecho

de que GraphSAGE mantenga la primera posición en ambos esquemas sugiere que esta arquitectura presenta una buena capacidad para capturar relaciones espaciales útiles en la Sierra.

Desde el punto de vista de la estabilidad, GATv2 volvió a mostrar una menor variabilidad entre corridas, particularmente en RMSE, aunque sin superar el desempeño promedio de GraphSAGE. Por su parte, los modelos baseline conservaron un comportamiento claramente inferior, lo que indica que la inclusión de coordenadas como variables auxiliares no fue suficiente para compensar la ausencia de una representación relacional explícita del espacio.

Con el fin de complementar los resultados expuestos en esta subsección, en el Anexo 1 se presentan los mapas predictivos correspondientes a la región Sierra bajo el esquema transductivo, en el Anexo 2 los gráficos de error con componente espacial, y en el Anexo 3 los gráficos comparativos entre valores reales y valores predichos. La consulta de estos anexos permite profundizar en la interpretación espacial del comportamiento de los modelos.

Comparación entre el esquema inductivo y el esquema transductivo en la Sierra

Al comparar ambos esquemas, se observa que las diferencias entre ellos fueron relativamente pequeñas para los dos modelos basados en grafos. En el caso de GraphSAGE, el esquema inductivo mostró un desempeño ligeramente mejor, con un RMSE medio menor y un R^2 medio mayor que en el esquema transductivo. Una tendencia similar se observó en GATv2, aunque con una magnitud también reducida. Este comportamiento sugiere que, al menos en la configuración experimental utilizada, la disponibilidad de un grafo conjunto en el esquema transductivo no generó una mejora sustancial respecto del escenario inductivo.

En términos globales, los resultados obtenidos para la región Sierra permiten destacar tres hallazgos principales. En primer lugar, los modelos basados en grafos superaron consistentemente a los modelos baseline en ambos esquemas de aprendizaje. En segundo lugar, GraphSAGE fue el modelo con mejor desempeño promedio tanto en el enfoque inductivo como en el transductivo. En tercer lugar, las diferencias entre ambos esquemas fueron moderadas, lo que sugiere que la ventaja principal no provino tanto del tipo de esquema empleado, sino de la capacidad de las arquitecturas GNN para incorporar la estructura espacial de manera explícita.

Para una evaluación más detallada de las diferencias entre ambos esquemas en la región Sierra, se recomienda revisar los anexos del informe. En el Anexo 1 se incluyen los mapas predictivos de ambos enfoques, en el Anexo 2 los gráficos de error espacial, y en el Anexo 3 los gráficos comparativos de valores observados y predichos. Estos insumos permiten complementar la comparación desarrollada en esta sección desde una perspectiva visual y territorial.

5.3. Resultados de los modelos a nivel región Costa

La evaluación regional para la Costa permitió examinar el comportamiento de los modelos en un dominio espacial distinto al conjunto nacional y a la región Sierra, caracterizado por condiciones ambientales, topográficas y climáticas particulares. En este caso, el análisis se realizó sobre un subconjunto de 1519 observaciones, obtenido mediante el filtrado regional de la base original. En todas las corridas se mantuvo la misma estructura general del conjunto de datos, con 81 columnas originales, 32 variables excluidas por razones estructurales o de posible fuga de información y 4 variables eliminadas por presentar más del 40 % de valores faltantes. A diferencia de los análisis anteriores, en la Costa también fue descartada la variable correspondiente al índice topográfico de humedad (TWI, Topographic Wetness Index), por lo que el conjunto final quedó conformado por 45 variables predictoras.

Este comportamiento fue consistente a través de las cinco corridas realizadas en ambos esquemas experimentales, lo que confirma la estabilidad de la etapa de preparación de datos para esta región. No obstante, a diferencia de lo observado en Ecuador y en la Sierra, los resultados de la Costa muestran un patrón distinto en la comparación entre modelos. En este caso, los modelos baseline y GATv2 presentaron desempeños muy similares, mientras que GraphSAGE mostró un comportamiento considerablemente más inestable y un desempeño promedio claramente inferior. Esta diferencia regional resulta especialmente relevante para la interpretación metodológica del estudio, ya que sugiere que el valor agregado de la estructura espacial no fue uniforme en todos los dominios analizados.

5.3.1 Resultados de la Experimentación inductiva a nivel región Costa

En el esquema inductivo, los modelos fueron entrenados y evaluados sobre subconjuntos separados, de modo que la predicción se realizara en un escenario de generalización espacial más exigente. El resumen promedio de las cinco corridas muestra que el mejor

desempeño correspondió a Random Forest, seguido muy de cerca por GATv2, mientras que Extra Trees se ubicó en una posición intermedia y GraphSAGE registró el menor desempeño promedio, acompañado de una variabilidad muy elevada entre corridas.

La Tabla 8 muestra que, en la Costa y bajo el esquema inductivo, Random Forest obtuvo el mejor desempeño promedio, con un RMSE medio de 13.2371 y un R^2 medio de 0.4489. El segundo lugar correspondió a GATv2, con un RMSE medio de 13.2470 y un R^2 medio de 0.4474, es decir, con un comportamiento prácticamente equivalente al de Random Forest. Extra Trees presentó un desempeño algo inferior, con un RMSE medio de 13.5727 y un R^2 medio de 0.4204. En contraste, GraphSAGE mostró un deterioro importante en el ajuste, con un RMSE medio de 16.0083 y un R^2 medio de 0.1076, acompañado además de desviaciones estándar notablemente superiores a las del resto de modelos.

Modelo	RMSE medio	Desviación estándar RMSE	R^2 medio	Desviación estándar R^2
Random Forest	13.2371	1.1325	0.4489	0.0322
GATv2	13.247	1.6112	0.4474	0.0787
Extra Trees	13.5727	1.1743	0.4204	0.0388
GraphSAGE	16.0083	5.5865	0.1076	0.7112

Tabla 8. Resumen promedio de métricas en prueba para la experimentación inductiva en la región Costa

Estos resultados evidencian una diferencia relevante respecto de los casos analizados previamente. En la Costa, la ventaja de los modelos basados en grafos no fue generalizada. Por el contrario, el mejor desempeño correspondió a un modelo baseline, mientras que GATv2 alcanzó un resultado prácticamente indistinguible del de Random Forest. Esta proximidad sugiere que, para este dominio regional y bajo el esquema inductivo, la incorporación explícita de la estructura espacial no produjo una mejora clara sobre el modelo tabular de referencia. En términos prácticos, la señal espacial disponible parece haber sido capturada con una eficacia comparable por Random Forest mediante la incorporación de coordenadas como variables auxiliares.

El caso de GraphSAGE merece una atención particular. Además de presentar el peor desempeño promedio, registró una variabilidad excepcionalmente alta tanto en RMSE como en R^2 , lo que indica una fuerte inestabilidad entre corridas. Esta situación sugiere que la arquitectura fue especialmente sensible a la partición del conjunto de datos o a la configuración del entrenamiento en la región Costa. Por tanto, más que una diferencia menor de ajuste, en este caso se observa una pérdida importante de robustez

metodológica frente a GATv2 y frente a los modelos baseline.

Como apoyo a la interpretación de los resultados presentados en esta subsección, en el Anexo 1 se encuentran los mapas predictivos de la región Costa bajo el esquema inductivo, en el Anexo 2 los gráficos de error espacial, y en el Anexo 3 los gráficos comparativos entre valores observados y valores predichos. Estos productos gráficos permiten examinar con mayor detalle la distribución espacial de las predicciones y la consistencia del ajuste alcanzado.

5.3.2 Resultados de la Experimentación transductiva a nivel región Costa

En el esquema transductivo, el entrenamiento y la evaluación se desarrollaron sobre un grafo conjunto que integró simultáneamente las observaciones de entrenamiento y prueba, manteniendo la separación entre ambas mediante máscaras internas. Este planteamiento permitió a los modelos basados en grafos aprovechar la conectividad espacial global del conjunto de datos. Sin embargo, los resultados obtenidos para la Costa muestran que esta ventaja metodológica no se tradujo de manera homogénea en una mejora del desempeño.

La Tabla 9 muestra que, en el esquema transductivo, GATv2 alcanzó el mejor desempeño promedio, aunque por un margen extremadamente reducido respecto de Random Forest. En particular, GATv2 obtuvo un RMSE medio de 13.2201 y un R^2 medio de 0.4496, mientras que Random Forest registró un RMSE medio de 13.2371 y un R^2 medio de 0.4489. Esta diferencia es mínima, por lo que ambos modelos pueden considerarse prácticamente equivalentes en términos de desempeño promedio. Por su parte, Extra Trees mantuvo una posición intermedia, mientras que GraphSAGE volvió a presentar el peor desempeño y una variabilidad muy elevada entre corridas.

Modelo	RMSE medio	Desviación estándar RMSE	R^2 medio	Desviación estándar R^2
GATv2	13.2201	1.6398	0.4496	0.0807
Random Forest	13.2371	1.1325	0.4489	0.0322
Extra Trees	13.5727	1.1743	0.4204	0.0388
GraphSAGE	16.0143	5.5804	0.1071	0.7109

Tabla 9. Resumen promedio de métricas en prueba para la experimentación transductiva en la región Costa

Desde una perspectiva comparativa, estos resultados indican que, en la región Costa, el uso de un grafo conjunto en el esquema transductivo no generó una mejora sustancial respecto del esquema inductivo. GATv2 mejoró levemente hasta ubicarse por encima de

Random Forest, pero la magnitud de la diferencia fue marginal. Esto sugiere que, si bien la estructura espacial pudo aportar cierta información adicional, su efecto fue reducido y no modificó de manera importante la jerarquía general de los modelos más competitivos. En cambio, Random Forest mantuvo un comportamiento notablemente sólido, lo que refuerza su condición de baseline robusto en este dominio regional.

Al igual que en el esquema inductivo, GraphSAGE mostró un comportamiento claramente desfavorable. La combinación de un R^2 medio muy bajo con una desviación estándar extremadamente alta indica que el modelo no solo fue menos preciso, sino también poco estable. Por tanto, en el caso de la Costa, GraphSAGE no logró beneficiarse de la estructura espacial de manera consistente y su rendimiento quedó por debajo tanto de GATv2 como de los modelos baseline.

Los resultados obtenidos para la región Costa bajo el esquema transductivo pueden complementarse mediante la revisión de los anexos del informe. En el Anexo 1 se incluyen los mapas predictivos correspondientes, en el Anexo 2 los gráficos de error con componente espacial, y en el Anexo 3 los gráficos comparativos de valores reales y valores predichos. Estos materiales permiten ampliar la evaluación del desempeño de los modelos desde una perspectiva gráfica y espacial.

Comparación entre el esquema inductivo y el esquema transductivo en la Costa

La comparación entre ambos esquemas revela diferencias muy pequeñas en la región Costa. En el caso de GATv2, el esquema transductivo mostró una mejora marginal frente al inductivo, reflejada en un RMSE ligeramente menor y un R^2 ligeramente mayor. No obstante, esta mejora fue de escasa magnitud. En Random Forest y Extra Trees, las métricas medias se mantuvieron idénticas entre ambos resúmenes compartidos. Por su parte, GraphSAGE mostró prácticamente el mismo comportamiento en ambos esquemas, conservando un rendimiento bajo y una elevada inestabilidad.

En términos generales, los resultados de la Costa permiten destacar tres hallazgos principales. En primer lugar, a diferencia de lo observado en Ecuador y en la Sierra, la superioridad de los modelos basados en grafos no fue clara en esta región. En segundo lugar, Random Forest y GATv2 constituyeron las dos alternativas de mejor desempeño, con diferencias prácticamente nulas entre sí. En tercer lugar, GraphSAGE presentó una pérdida importante de precisión y estabilidad, lo que indica que la utilidad de la estructura espacial no fue homogénea entre arquitecturas ni entre dominios regionales.

En conjunto, la región Costa muestra un patrón distinto al observado en la Sierra: aquí, los modelos baseline conservaron una competitividad muy alta y la ventaja de las arquitecturas basadas en grafos fue, en el mejor de los casos, marginal. Este resultado es importante para la discusión general del estudio, ya que sugiere que el valor agregado de los enfoques GNN depende del contexto espacial y no puede asumirse como uniforme en todos los dominios geográficos analizados.

Para complementar la comparación entre ambos esquemas en la región Costa, se recomienda consultar los anexos del informe. En el Anexo 1 se presentan los mapas predictivos asociados a ambos enfoques, en el Anexo 2 los gráficos de error espacial, y en el Anexo 3 los gráficos comparativos entre valores observados y valores predichos. Estos insumos permiten contrastar visualmente los patrones espaciales y el comportamiento predictivo descritos en esta subsección.

6. Discusión

En el marco del proyecto PIS-24-09, el presente informe permitió evaluar comparativamente la capacidad de distintos modelos para capturar la dinámica del carbono orgánico del suelo en Ecuador, tanto a escala nacional como en los dominios regionales de Sierra y Costa. En términos generales, los resultados muestran que la estructura espacial aportó información relevante para la predicción del SOC, aunque su efecto no fue uniforme entre regiones ni entre arquitecturas. Esto indica que el valor de los modelos basados en grafos depende del contexto territorial y de la manera en que la dependencia espacial se manifiesta en cada dominio de análisis. Además, esta discusión incorpora un análisis del impacto técnico de cada metodología, con especial atención a la eficiencia relativa de las arquitecturas basadas en grafos frente a los modelos baseline.

A escala nacional, los resultados evidenciaron una ventaja clara de las arquitecturas basadas en grafos frente a los modelos baseline. En el esquema inductivo, GraphSAGE presentó el mejor desempeño promedio, mientras que en el esquema transductivo la primera posición fue ocupada por GATv2. Esta diferencia sugiere que el uso de un grafo global favoreció especialmente a GATv2, probablemente porque su mecanismo de atención permitió ponderar con mayor eficacia la influencia relativa de los nodos vecinos cuando dispuso de la estructura espacial completa. En conjunto, los resultados a nivel Ecuador indican que la conectividad espacial entre observaciones contiene información útil para la predicción del carbono orgánico del suelo y que su incorporación explícita puede traducirse en mejoras frente a enfoques tabulares convencionales.

La región Sierra constituyó el caso más favorable para las arquitecturas basadas en grafos. Tanto en el esquema inductivo como en el transductivo, GraphSAGE y GATv2 superaron con claridad a Random Forest y Extra Trees, y en ambos casos GraphSAGE alcanzó el mejor desempeño promedio. La diferencia con respecto a los modelos baseline fue más marcada que la observada a escala nacional, lo que sugiere que en la Sierra la dependencia espacial del fenómeno fue especialmente informativa. Este comportamiento puede interpretarse en relación con la heterogeneidad topográfica y ambiental de la región, donde la proximidad entre observaciones parece reflejar de mejor manera gradientes territoriales relevantes para la distribución del SOC.

La región Costa, en cambio, mostró un patrón distinto. En este caso, la ventaja de los modelos basados en grafos no fue generalizada. En el esquema inductivo, Random Forest obtuvo el mejor desempeño promedio y GATv2 presentó un resultado prácticamente equivalente; en el esquema transductivo, GATv2 pasó a ocupar la primera posición, pero por un margen mínimo respecto de Random Forest. Esto indica que, en este dominio regional, la incorporación explícita de la estructura espacial no produjo una mejora sustancial sobre el baseline más robusto. Además, GraphSAGE presentó un deterioro importante tanto en precisión como en estabilidad, lo que evidencia que la utilidad del grafo depende no solo de la existencia de relaciones espaciales, sino también de la capacidad de la arquitectura para explotarlas de manera consistente en un contexto territorial específico.

En síntesis, la comparación entre Ecuador, Sierra y Costa muestra que la estructura espacial sí aportó valor para la predicción del carbono orgánico del suelo, pero su efecto fue claramente contextual. La mejora fue evidente a escala nacional y especialmente sólida en la Sierra, mientras que en la Costa resultó más limitada. Por tanto, el principal hallazgo de esta discusión no es únicamente que las GNN pueden superar a los modelos baseline, sino que su potencial emerge con mayor claridad cuando la dependencia espacial del fenómeno es suficientemente informativa y cuando la arquitectura seleccionada es capaz de explotarla de forma estable y robusta.

6.1 Análisis del impacto técnico de cada metodología

Desde el punto de vista técnico, los resultados permiten distinguir fortalezas metodológicas diferentes entre los modelos evaluados. Random Forest se consolidó como el baseline más robusto del estudio, con un comportamiento competitivo en todos los escenarios y resultados particularmente sólidos en la Costa. Su principal fortaleza

radicó en su estabilidad y en su capacidad para capturar relaciones no lineales entre variables sin requerir una estructura relacional explícita. Extra Trees, por su parte, mostró un desempeño sistemáticamente inferior al de Random Forest, lo que indica que su mayor aleatorización no se tradujo en una ventaja clara dentro del contexto analizado. En consecuencia, aunque ambos modelos constituyen referencias válidas para problemas de regresión ambiental, su capacidad para representar la dependencia espacial del SOC resultó más limitada que la observada en las arquitecturas basadas en grafos.

En el caso de las GNN, el principal aporte técnico consistió en incorporar de manera explícita la estructura espacial entre observaciones, permitiendo aprovechar la conectividad entre puntos de muestreo como una fuente adicional de información predictiva. Esta característica resultó especialmente eficiente en aquellos contextos donde la dependencia espacial fue más informativa, como ocurrió a escala nacional y, con mayor claridad, en la región Sierra. En estos escenarios, los modelos basados en grafos no solo superaron a los baseline, sino que además lo hicieron de manera consistente bajo distintos esquemas experimentales, lo que refuerza la idea de que la estructura relacional del espacio constituye una dimensión metodológicamente relevante para el modelado del carbono orgánico del suelo.

Entre las dos arquitecturas GNN evaluadas, GATv2 mostró un balance técnico particularmente favorable. Su buen desempeño a escala nacional y en la Costa transductiva, junto con una variabilidad relativamente contenida entre corridas, sugiere que el mecanismo de atención permitió una utilización eficiente de la información espacial disponible. GraphSAGE, en cambio, mostró un comportamiento más dependiente del contexto. Su mejor desempeño se observó en la Sierra, donde logró superar de forma clara a los demás modelos, pero su respuesta fue menos homogénea en otros dominios, especialmente en la Costa, donde presentó una pérdida importante de estabilidad. Esto indica que, aunque GraphSAGE puede ser muy eficiente cuando la estructura espacial del fenómeno está bien definida, su rendimiento puede ser más sensible al dominio regional y a la configuración experimental.

La eficiencia relativa de las GNN, por tanto, no debe entenderse únicamente como una superioridad en métricas, sino como una mejor capacidad para aprovechar la dependencia espacial cuando está realmente contiene señal útil. Bajo esta interpretación, el principal aporte técnico de las arquitecturas basadas en grafos en este informe no fue reemplazar por completo a los modelos baseline, sino demostrar que, en contextos

adecuados, pueden constituir una alternativa más informativa y más cercana a la naturaleza espacial del problema. Esta es precisamente la razón por la cual las GNN representan el avance metodológico más relevante del estudio.

Ahora bien, este análisis técnico debe interpretarse considerando varias limitaciones. En primer lugar, aunque el conjunto de covariables fue amplio y multimodal, estuvo compuesto principalmente por información derivada de sensores remotos, atributos topográficos y variables climáticas. En futuras etapas sería recomendable incorporar covariables provenientes de otras fuentes no estrictamente asociadas a imágenes satelitales, como información geológica, material parental, clases de suelo, uso y manejo del suelo u otras variables edáficas complementarias. En segundo lugar, la configuración experimental estuvo condicionada por restricciones de tiempo de ejecución y capacidad de cómputo, particularmente en términos de procesamiento y disponibilidad de GPU, es decir, unidades de procesamiento gráfico. Esto limitó el número de iteraciones, validaciones, escenarios y configuraciones de entrenamiento exploradas, especialmente en los modelos basados en grafos, cuyo costo computacional fue superior al de los baseline.

También existen limitaciones específicas asociadas a los modelos baseline. Aunque Random Forest y Extra Trees pueden incorporar coordenadas como variables auxiliares, esto no equivale a modelar explícitamente la conectividad espacial entre observaciones. En consecuencia, estos enfoques pueden capturar señal locacional directa, pero no aprovechan formalmente relaciones de vecindad ni mecanismos de propagación de información sobre un grafo. Esta diferencia metodológica ayuda a explicar por qué, en varios escenarios, los modelos GNN mostraron ventajas claras frente a los enfoques tabulares, especialmente en Ecuador y, con mayor intensidad, en la Sierra.

Estas limitaciones no invalidan los hallazgos del estudio, pero sí delimitan su alcance actual. Precisamente por ello, en la futura redacción del artículo científico derivado del proyecto PIS-24-09 será necesario ampliar el conjunto de covariables con nuevas fuentes de información no satelitales, fortalecer la infraestructura computacional disponible y extender el protocolo experimental a un mayor número de iteraciones, validaciones y configuraciones de entrenamiento. Esto permitirá evaluar con mayor profundidad la estabilidad de los resultados y fortalecer la comparación entre modelos baseline y arquitecturas basadas en grafos bajo un marco metodológico más amplio y exigente.

7. Conclusiones

En el marco del proyecto PIS-24-09, el presente informe permitió evaluar comparativamente la capacidad de los modelos GraphSAGE, GATv2, Random Forest y Extra Trees para estimar el carbono orgánico del suelo en Ecuador, considerando tanto el conjunto nacional como los dominios regionales de Sierra y Costa. En términos generales, los resultados muestran que la incorporación explícita de la estructura espacial puede mejorar la predicción del SOC, aunque este beneficio no se manifestó de manera homogénea en todos los escenarios analizados.

A escala nacional, los modelos basados en grafos presentaron el mejor desempeño global. En el esquema inductivo, GraphSAGE alcanzó el mejor resultado promedio, mientras que en el esquema transductivo GATv2 ocupó la primera posición. La comparación entre ambos enfoques mostró además que el esquema transductivo favoreció especialmente a las arquitecturas GNN, lo que confirma que la conectividad espacial global del conjunto de datos constituye una fuente de información relevante para la estimación del carbono orgánico del suelo en Ecuador.

En la región Sierra, los resultados fueron consistentes en ambos esquemas experimentales. Tanto GraphSAGE como GATv2 superaron de forma clara a los modelos baseline, y en ambos casos GraphSAGE obtuvo el mejor desempeño promedio. Este comportamiento permite concluir que, en este dominio regional, la estructura espacial del fenómeno fue especialmente informativa y que las arquitecturas basadas en grafos lograron capturarla con mayor eficacia que los modelos tabulares convencionales. Por ello, la Sierra constituye el caso más sólido a favor del uso de GNN dentro del presente estudio.

En la región Costa, en cambio, los resultados mostraron un patrón diferente. Allí, la ventaja de los modelos basados en grafos no fue generalizada. Random Forest y GATv2 presentaron desempeños prácticamente equivalentes, tanto en el esquema inductivo como en el transductivo, mientras que GraphSAGE mostró un rendimiento claramente inferior y una inestabilidad muy alta. Este resultado indica que la utilidad de la estructura espacial no es uniforme entre regiones y que, en determinados contextos, un modelo baseline robusto puede mantener un desempeño tan competitivo como una arquitectura basada en grafos.

Desde una perspectiva comparativa entre modelos, es posible destacar tres hallazgos principales. En primer lugar, GATv2 mostró el mejor desempeño global a escala nacional en el esquema transductivo, lo que lo posiciona como la arquitectura más competitiva para

el caso general de Ecuador. En segundo lugar, GraphSAGE fue el modelo más fuerte en la Sierra, donde la señal espacial pareció ser más informativa y mejor aprovechada por este esquema de agregación. En tercer lugar, Random Forest se consolidó como el baseline más robusto del estudio, manteniéndose competitivo en todos los casos y alcanzando resultados prácticamente equivalentes al mejor modelo en la Costa. Por su parte, Extra Trees mostró un comportamiento sistemáticamente inferior al de Random Forest, sin llegar a posicionarse como la mejor alternativa en ninguno de los dominios evaluados.

El estudio también permitió concluir que la comparación entre esquemas inductivo y transductivo aporta información metodológica valiosa. El enfoque transductivo mejoró de forma clara el desempeño de las arquitecturas GNN a escala nacional, mientras que en la Sierra y en la Costa las diferencias entre ambos esquemas fueron menores. Esto sugiere que el beneficio del grafo global no es igualmente fuerte en todos los dominios y que la utilidad de uno u otro enfoque depende de la manera en que la estructura espacial del fenómeno se expresa en cada región. En consecuencia, la elección entre enfoque inductivo y transductivo no debería asumirse de forma automática, sino evaluarse en función de la escala y del comportamiento espacial del área de estudio.

Asimismo, los resultados permiten concluir que las ventajas de los modelos baseline y de los modelos basados en grafos son de naturaleza distinta. Los baseline, particularmente Random Forest, ofrecieron robustez, estabilidad y competitividad, pero con una capacidad limitada para representar explícitamente relaciones espaciales entre observaciones. Las arquitecturas GNN, en cambio, mostraron un mayor potencial cuando la dependencia espacial fue suficientemente informativa, aunque también una sensibilidad mayor al contexto regional y a la configuración experimental. Esta diferencia confirma que el valor de las GNN en el mapeo digital de suelos no debe interpretarse como una superioridad universal, sino como una ventaja contextual que depende del territorio, de la escala de análisis y de la arquitectura seleccionada.

Finalmente, debe reconocerse que las conclusiones de este informe corresponden a una etapa experimental desarrollada bajo restricciones operativas de tiempo y capacidad de cómputo, con un número moderado de repeticiones, evaluaciones de hiperparámetros y épocas de entrenamiento. Asimismo, el conjunto de covariables, aunque amplio, se apoyó principalmente en información satelital, topográfica y climática. Por ello, en una etapa posterior orientada a la redacción del artículo científico derivado del proyecto PIS-24-09,

será recomendable ampliar las fuentes de información mediante covariables adicionales no satelitales, incrementar la infraestructura computacional disponible y extender el protocolo experimental con un mayor número de iteraciones, escenarios y validaciones. Esto permitirá fortalecer la robustez estadística del análisis y verificar con mayor profundidad la estabilidad de las tendencias observadas.

En síntesis, el principal aporte de este informe consiste en demostrar que los modelos basados en grafos tienen un potencial real para mejorar la estimación del carbono orgánico del suelo en Ecuador, especialmente cuando la dependencia espacial del fenómeno es suficientemente informativa, como ocurrió a escala nacional y, con mayor claridad, en la Sierra. Sin embargo, también se demuestra que esta ventaja no es automática ni uniforme, y que modelos baseline robustos como Random Forest pueden mantener un desempeño altamente competitivo en determinados contextos, como la Costa. Esta conclusión constituye el hallazgo central del estudio y proporciona una base sólida para futuras investigaciones orientadas a optimizar el uso de arquitecturas GNN en aplicaciones de mapeo digital de suelos en el contexto ecuatoriano.

6. Bibliografía

- Bergstra, J., Yamins, D., & Cox, D. D. (2013). Making a science of model search: Hyperparameter optimization in hundreds of dimensions for vision architectures. *Proceedings of the 30th International Conference on Machine Learning*, 115–123.
- Brody, S., Alon, U., & Yahav, E. (2022). How attentive are graph attention networks? *International Conference on Learning Representations*.
- Fey, M., & Lenssen, J. E. (2019). Fast graph representation learning with PyTorch Geometric. *International Conference on Learning Representations Workshop on Representation Learning on Graphs and Manifolds*.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations*.
- McBratney, A. B., Mendonça Santos, M. L., & Minasny, B. (2003). On digital soil mapping. *Geoderma*, 117(1–2), 3–52. [https://doi.org/10.1016/S0016-7061\(03\)00223-4](https://doi.org/10.1016/S0016-7061(03)00223-4)
- Minasny, B., & McBratney, A. B. (2016). Digital soil mapping: A brief history and some lessons. *Geoderma*, 264, 301–311. <https://doi.org/10.1016/j.geoderma.2015.10.025>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python.

Unidad de Gestión de Investigación y Proyección Social

Edificio 3, Primer piso

Av. Ladrón de Guevara E11-253 y Andalucía

Teléfono: 2976300 Ext. 1066

- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., & Bengio, Y. (2018). Graph attention networks. *International Conference on Learning Representations*.

7. Anexos

Anexo 1. Mapas predictivos de los modelos evaluados
Este anexo contiene los mapas predictivos generados para todos los casos de experimentación, incluyendo el nivel nacional de Ecuador y los análisis regionales de Sierra y Costa, bajo los esquemas inductivo y transductivo. Enlace: [\[Anexo 1 – Mapas predictivos de los modelos evaluados\]](#)

Anexo 2. Gráficos de error con componente espacial de los modelos evaluados
Este anexo reúne los gráficos de error espacial obtenidos para todos los casos de experimentación, incluyendo Ecuador, Sierra y Costa, en los esquemas inductivo y transductivo. Enlace: [\[Anexo 2 – Gráficos de error con componente espacial de los modelos evaluados\]](#)

Anexo 3. Gráficos comparativos de valor real frente a valor predicho
Este anexo incluye los gráficos comparativos entre valores observados y valores predichos para todos los modelos y todos los casos de experimentación, tanto a nivel nacional como regional, en los esquemas inductivo y transductivo. Enlace: [\[Anexo 3 – Gráficos comparativos de valor real frente a valor predicho\]](#)

Anexo 4. Código de Python de implementación de GraphSAGE Esquema Inductivo: [Anexo 4. Código de Python de implementación de GraphSAGE Esquema Inductivo.ipynb](#)

Anexo 5. Código de Python de implementación de GraphSAGE Esquema Transductivo: [Anexo 5. Código de Python de implementación de GraphSAGE Esquema Transductivo.ipynb](#)

Anexo 6. Código de Python de implementación GATv2 Esquema Inductivo: [Anexo 6. Código de Python de implementación GATv2 Esquema Inductivo.ipynb](#)

Anexo 7. Código de Python de implementación de GATv2 Esquema Transductivo : [Anexo 7. Código de Python de implementación de GATv2 Esquema Transductivo.ipynb](#)

Elaborado por:
Nombre: Mateo Xavier Soliz Villafuerte
Servidor Público 5

Aprobado por:
Nombre: David Andrés Donoso Vargas
Director del Proyecto PIS-24-09