

INFORME MENSUAL DE PRODUCTOS ENTREGADOS

NOMBRE DEL PRODUCTO:	<i>Informe de Selección y Diseño de Arquitecturas de Redes Neuronales (énfasis en GNN)</i>
CÓDIGO PROYECTO:	<i>PIS-24-09.</i>
NOMBRE DE PROYECTO:	Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales
NOMBRE DEL PROFESIONAL:	Mateo Xavier Soliz Villafuerte
PERÍODO:	<i>19 de octubre de 2025 al 18 de noviembre de 2025</i>
FECHA DE PRESENTACIÓN:	<i>18 de noviembre de 2025</i>

1. OBJETIVO

El objetivo principal de este informe es documentar el proceso de selección, revisión y diseño técnico de arquitecturas de Redes Neuronales de Grafos (GNN) orientadas a la estimación del Carbono Orgánico del Suelo (SOC) en Ecuador, en el marco del proyecto PIS-24-09 “Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales”.

Este producto establece los fundamentos teóricos, metodológicos y comparativos necesarios para determinar las arquitecturas de GNN más adecuadas, considerando la complejidad espacial del SOC, la heterogeneidad de la distribución de muestreo, y la necesidad de modelos inductivos escalables a nivel nacional.

2. ACTIVIDADES REALIZADAS

Durante el desarrollo del presente producto se ejecutaron las siguientes actividades:

1. Revisión exhaustiva de literatura especializada en GNN aplicadas a datos geoespaciales:

- Se analizaron enfoques clásicos y recientes sobre aprendizaje en grafos, incluyendo GCN, GraphSAGE, Graph Attention Networks (GAT) y ASI-GCN.
- Se revisaron trabajos de referencia relacionados con DSM, aprendizaje geométrico profundo y operadores espaciales avanzados.
- Se evaluaron estudios que abordan explícitamente problemas análogos al SOC, especialmente en contextos de datos dispersos y escenarios con alta heterogeneidad espacial.

2. Análisis comparativo de arquitecturas:

- Se evaluaron ventajas, limitaciones, complejidad computacional y capacidad inductiva de cada arquitectura.
- Se construyó una tabla comparativa que incluye mecanismos espaciales, preservación de varianza, capacidad para modelar anisotropía y escalabilidad.
- Se sintetizó evidencia empírica disponible sobre el comportamiento de cada arquitectura frente a problemas de suavizado, pérdida de heterogeneidad y generalización a nodos

Unidad de Gestión de Investigación y Proyección Social

Edificio 3, Primer piso

Av. Ladrón de Guevara E11-253 y Andalucía

Teléfono: 2976300 Ext. 1066

no vistos.

3. **Diseño técnico de las cuatro arquitecturas a implementar:** Para cada arquitectura (GCN, GraphSAGE/PESAGE, GAT y ASI-GCN) se desarrolló:

- Definición del grafo y mecanismos espaciales.
- Número de capas, activaciones, regularización y funciones de pérdida.
- Especificaciones de entrenamiento, normalización, y criterios de validación.
- Identificación de métricas de evaluación apropiadas (MAE, RMSE, R^2 , Moran's I).

4. **Construcción del marco metodológico:**

- Se justificó la selección de GraphSAGE (PESAGE) como arquitectura central, basándose en su capacidad inductiva, preservación de información local mediante concatenación, y robustez ante heterogeneidad espacial.
- Se definieron lineamientos técnicos para la etapa posterior de implementación con datos SOC Ecuador 2021.

5. **Elaboración del informe técnico**

- Se estructuraron las secciones de introducción, revisión teórica, comparaciones, diseño de modelos y conclusiones.
- Se incorporaron citas bibliográficas completas de todas las fuentes científicas utilizadas en el análisis.

3. PRODUCTOS ALCANZADOS

6. **Elaboración del informe técnico**

- Se estructuraron las secciones de introducción, revisión teórica, comparaciones, diseño de modelos y conclusiones.
- Se incorporaron citas bibliográficas completas de todas las fuentes científicas utilizadas en el análisis.

Los productos generados en esta fase incluyen:

1. **Informe técnico de selección y diseño de arquitecturas GNN**

Documento completo con revisión conceptual, análisis comparativo, fundamentos metodológicos y especificaciones técnicas de implementación de las cuatro arquitecturas evaluadas.

2. **Tabla comparativa de arquitecturas GNN**

Incluye ventajas, limitaciones, mecanismos espaciales y aplicabilidad de GCN, GraphSAGE, GAT y ASI-GCN.

3. **Especificación técnica detallada de cada arquitectura**

Tablas con hiperparámetros sugeridos, funciones de activación, estrategias de regularización, métodos de construcción de grafos y criterios de evaluación.

4. **Marco metodológico para modelamiento futuro**

Base conceptual para implementar modelos inductivos escalables (especialmente PESAGE), orientados al mapeo nacional del SOC.

Estos productos constituyen la base teórica y metodológica para la fase de implementación con datos reales y el diseño de modelos predictivos basados en GNN.

4. REFERENCIAS

- Appleby, G., Liu, L., & Liu, L. (2023). Kriging Convolutional Networks. arXiv preprint arXiv:2306.09463. <https://arxiv.org/abs/2306.09463>
- Dong, Y., Ding, K., Jalaian, B., Ji, S., & Li, J. (2021). AdaGNN: Graph Neural Networks with Adaptive Frequency Response Filter. arXiv preprint arXiv:2104.12840. <https://arxiv.org/abs/2104.12840>
- Li, Y., Yu, D., Liu, Z., Zhang, M., Gong, X., & Zhao, L. (2023). Graph neural network for spatiotemporal data: Methods and applications. arXiv preprint arXiv:2306.00012. <https://arxiv.org/abs/2306.00012>
- McBratney, A. B., Santos, M. M., & Minasny, B. (2003). On digital soil mapping. *Geoderma*, 117(1–2), 3–52. [https://doi.org/10.1016/S0016-7061\(03\)00223-4](https://doi.org/10.1016/S0016-7061(03)00223-4)
- Padarian, J., Minasny, B., & McBratney, A. B. (2019). Using deep learning for digital soil mapping. *SOIL*, 5(1), 79–89. <https://doi.org/10.5194/soil-5-79-2019>
- Soliz Villafuerte, M. X., & Donoso Vargas, D. A. (2025). Informe de Preprocesamiento de Datos (Producto 2 del Proyecto PIS-24-09: Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales). Escuela Politécnica Nacional.
- Tao, H., Li, Z., Nie, S., Li, H., & Zhao, D. (2025). An adaptive graph convolutional network with spatial autocorrelation for enhancing 3D soil pollutant mapping precision from sparse borehole data. *Land*, 14(7), 1348. <https://doi.org/10.3390/land14071348>
- Wadoux, A. M. J.-C., Minasny, B., & McBratney, A. B. (2020). Machine learning for digital soil mapping: Applications, challenges and suggested solutions. *Earth-Science Reviews*, 210, 103359. <https://doi.org/10.1016/j.earscirev.2020.103359>
- Wu, Y., Zhuang, D., Labbe, A., & Sun, L. (2021). Inductive graph neural networks for spatiotemporal kriging. *Proceedings of the AAAI Conference on Artificial Intelligence*, 35(4), 4478–4485.
- Yuan, D. (2025). Spatially directional dual-attention GAT for spatial fluoride health risk modeling. arXiv preprint arXiv:2504.09416. <https://arxiv.org/abs/2504.09416>
- Zeghina, A., Leborgne, A., Le Ber, F., & Vacavant, A. (2024). Deep learning on spatiotemporal graphs: A systematic review, methodological landscape, and research opportunities. *Neurocomputing*, 594, 127861. <https://doi.org/10.1016/j.neucom.2024.127861>
- Zhao, W., & Efremova, N. (2023). Soil organic carbon estimation from climate-related features with graph neural network. arXiv preprint arXiv:2311.15979. <https://arxiv.org/abs/2311.15979>
- Zhu, D., Liu, Y., Yao, X., & Fischer, M. M. (2021). Spatial regression graph convolutional neural networks: A deep learning paradigm for spatial multivariate distributions. *GeoInformatica*, 25, 873–910. <https://doi.org/10.1007/s10707-021-00454-x>

5. CONCLUSIONES

El análisis exhaustivo de literatura y el diseño metodológico desarrollado permiten concluir lo siguiente:

- Las Redes Neuronales de Grafos inductivas, especialmente GraphSAGE en configuración PESAGE, representan la alternativa más sólida para modelar el SOC en Ecuador debido a su capacidad para preservar heterogeneidad espacial y generalizar a

Unidad de Gestión de Investigación y Proyección Social

Edificio 3, Primer piso

Av. Ladrón de Guevara E11-253 y Andalucía

Teléfono: 2976300 Ext. 1066

zonas no muestreadas.

- Las arquitecturas GCN y GAT presentan limitaciones importantes asociadas al over-smoothing, pérdida de varianza espacial y alto costo computacional en escenarios con datos heterogéneos.
- Modelos más avanzados como ASI-GCN ofrecen ventajas para contextos de muestreo extremadamente disperso, pero su complejidad los hace menos adecuados para una implementación inicial a escala nacional.
- La arquitectura seleccionada provee un equilibrio óptimo entre robustez, escalabilidad, precisión y factibilidad computacional, sentando las bases para la fase de entrenamiento y validación con datos SOC 2021.
- El presente Informe de Selección y Diseño de Arquitecturas de Redes Neuronales (énfasis en GNN) consolida el marco conceptual, técnico y metodológico necesario para avanzar hacia la implementación de modelos predictivos que integren información climática, satelital y topográfica, contribuyendo al monitoreo ambiental nacional y a la gestión sostenible del recurso suelo.

6. ACEPTACIÓN

Firma Mateo Soliz en calidad de Servidor Público 5 (denominación del profesional descrito en el contrato) del Proyecto PIS-24-09 y el director del Proyecto David Andrés Donoso Vargas, en calidad de director del Proyecto PIS-24-09, para constancia de la recepción de este producto y su aprobación a entera satisfacción.

Elaborado por:	Aprobado por:
Nombre: Mateo Xavier Soliz Villafructe Servidor Público 5	Nombre: David Andrés Donoso Vargas Director del Proyecto PIS-24-09