

INFORME MENSUAL DE PRODUCTOS ENTREGADOS

NOMBRE DEL PRODUCTO:	<i>Implementación en Python de la Arquitectura Óptima de Red Neuronal Profunda para la Estimación y Predicción del SOC.</i>
CÓDIGO PROYECTO:	<i>PIS-24-09.</i>
NOMBRE DE PROYECTO:	Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales
NOMBRE DEL PROFESIONAL:	Mateo Xavier Soliz Villafuerte
PERÍODO:	<i>05 de febrero de 2026 al 04 de marzo de 2026</i>
FECHA DE PRESENTACIÓN:	<i>04 de marzo de 2026</i>

1. OBJETIVO

El objetivo del presente informe es describir y documentar el proceso de implementación en Python de arquitecturas avanzadas de Redes Neuronales de Grafos (GNN) para la estimación y predicción del Carbono Orgánico del Suelo (SOC) en Ecuador, en el marco del Proyecto PIS-24-09 “Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales”.

De manera específica, se busca establecer una base metodológica y computacional para el modelado del SOC mediante enfoques de aprendizaje profundo basados en grafos, integrando información geoespacial y ambiental, evaluando arquitecturas como GraphSAGE y GATv2 bajo esquemas de aprendizaje inductivo y transductivo, e implementando un protocolo experimental robusto que incluya optimización bayesiana de hiperparámetros y validación cruzada (convencional y espacial dependiendo si el esquema es inductivo o transductivo, respectivamente).

2. ACTIVIDADES REALIZADAS

Durante el período comprendido entre el 05 de febrero de 2026 y el 04 de marzo de 2026 se desarrollaron las siguientes actividades:

1. Definición del enfoque metodológico de modelización espacial:

- Se estableció la representación de los puntos de muestreo como nodos dentro de un grafo espacial.
- Se definió la construcción de aristas mediante distancia geodésica (*Haversine*) y el esquema de k-vecinos más cercanos (k -NN).

2. Construcción del grafo espacial:

- Se implementó el cálculo de distancias geográficas entre puntos de muestreo.
- Se desarrolló el procedimiento de construcción del grafo no dirigido.
- Se estructuró la representación computacional mediante objetos Data de *PyTorch Geometric* (*edge_index*, características y variable objetivo).

3. Implementación de arquitecturas de Redes Neuronales de Grafos:

- Se implementaron en *Python* las arquitecturas GraphSAGE y GATv2 como modelos de

Unidad de Gestión de Investigación y Proyección Social

Edificio 3, Primer piso

Av. Ladrón de Guevara E11-253 y Andalucía

Teléfono: 2976300 Ext. 1066

regresión sobre nodos espaciales.

- Se definieron clases derivadas de *torch.nn.Module* para estructurar las capas de convolución sobre grafos, mecanismos de agregación y atención.
- Se incorporaron mecanismos de atención multi-cabeza en GATv2 y funciones de agregación vecinal en GraphSAGE.

4. Diseño del protocolo experimental:

- Se estructuraron dos esquemas de aprendizaje: inductivo y transductivo.
- Se implementó partición de datos (80% entrenamiento, 20% prueba).
- Se desarrolló validación cruzada *k-Fold* (esquema inductivo).
- Se implementó validación cruzada espacial basada en K-Means (esquema transductivo).

5. Preprocesamiento de variables:

- Se realizó imputación de valores faltantes mediante mediana (*SimpleImputer*).
- Se implementaron diferentes estrategias de normalización (*StandardScaler*, *MinMaxScaler*, *RobustScaler*).

6. Optimización bayesiana de hiperparámetros:

- Se definió el espacio de búsqueda para hiperparámetros clave (*k_graph*, *hidden_dim*, *num_layers*, *learning_rate*, *dropout*, *weight_decay*, *residual*, *attention_heads*).
- Se implementó el algoritmo *Tree-structured Parzen Estimator* (TPE) mediante la biblioteca *Hyperopt*.

7. Estrategia de entrenamiento y regularización:

- Se utilizó el optimizador *Adam*.
- Se implementó la función de pérdida *Huber* (*Smooth L1 Loss*).
- Se incorporaron técnicas de regularización: *Dropout*, *DropEdge*, *regularización L2*, *gradient clipping* y *early stopping*.

8. Evaluación del desempeño predictivo:

- Se implementaron métricas de evaluación: RMSE, MAE, R^2 y MAPE.
- Se estructuró el almacenamiento de resultados experimentales para análisis comparativo.

9. Organización del pipeline computacional:

- Se desarrolló un flujo modular en *Python* que integra preprocesamiento, construcción del grafo, modelización, optimización, entrenamiento y evaluación.
- Se generaron notebooks de implementación para cada arquitectura y esquema experimental (inductivo y transductivo).

3. PRODUCTOS ALCANZADOS

Los productos generados durante el presente período incluyen:

1. Informe técnico de implementación de arquitecturas GNN:

Documento técnico que describe el marco metodológico, la formulación matemática, la construcción del grafo espacial, la implementación computacional y el protocolo experimental aplicado a la estimación del SOC.

2. Implementación en Python de GraphSAGE (Esquema Inductivo y Transductivo):

Código estructurado y documentado para el entrenamiento y evaluación de GraphSAGE bajo ambos esquemas experimentales.

3. Implementación en Python de GATv2 (Esquema Inductivo y Transductivo):

Unidad de Gestión de Investigación y Proyección Social

Edificio 3, Primer piso

Av. Ladrón de Guevara E11-253 y Andalucía

Teléfono: 2976300 Ext. 1066

Desarrollo de modelos con mecanismos de atención multi-cabeza para regresión sobre nodos espaciales.

4. Protocolo experimental reproducible :Pipeline modular que integra:

- Preprocesamiento de datos.
- Construcción de grafos espaciales.
- Optimización bayesiana de hiperparámetros.
- Entrenamiento con regularización y *early stopping*.
- Evaluación mediante métricas de regresión.

5. Espacio de búsqueda estructurado de hiperparámetros:

Definición formal y justificada de los hiperparámetros relevantes para GraphSAGE y GATv2.

6. Base metodológica para etapas posteriores del proyecto:

Lineamientos técnicos para la generación futura de mapas espaciales continuos de SOC mediante *Deep Learning* sobre grafos.

Estos productos constituyen un insumo técnico fundamental para la fase de modelización espacial y el desarrollo de modelos predictivos basados en enfoques avanzados, como las Redes Neuronales de Grafos y para la estimación del SOC en Ecuador.

4. REFERENCIAS

Instituto Nacional de Meteorología e Hidrología (INAMHI). (2021). Base de datos de mediciones de Carbono Orgánico del Suelo del Ecuador continental, proporcionada a través del Ministerio de Agricultura y Ganadería (MAGAP).

Soliz Villafuerte, M. X., & Donoso Vargas, D. A. (2026). Informe de Implementación en Python de la Arquitectura Óptima de Red Neuronal Profunda para la Estimación y Predicción del SOC. (Producto 2 del Proyecto PIS-24-09: Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales). Escuela Politécnica Nacional

Soliz Villafuerte, M. X., & Donoso Vargas, D. A. (2025). Informe de Preprocesamiento de Datos (Producto 2 del Proyecto PIS-24-09: Estimación del Carbono Orgánico del Suelo mediante Redes Neuronales de Grafos utilizando Datos Multimodales Geoespaciales). Escuela Politécnica Nacional.

5. CONCLUSIONES

El análisis desarrollado a partir del informe permite concluir lo siguiente:

- La representación de los puntos de muestreo como nodos dentro de un grafo espacial permite incorporar explícitamente la dependencia espacial en la estimación del SOC, superando la suposición de independencia entre observaciones presente en muchos modelos tradicionales.
- Las arquitecturas GraphSAGE y GATv2 constituyen enfoques complementarios para el modelado espacial del SOC, permitiendo capturar interacciones complejas mediante agregación vecinal y mecanismos de atención adaptativa.
- La comparación entre esquemas de aprendizaje inductivo y transductivo proporciona un marco riguroso para evaluar la capacidad de generalización espacial de los modelos.
- La incorporación de optimización bayesiana de hiperparámetros mejora la eficiencia del

Unidad de Gestión de Investigación y Proyección Social

Edificio 3, Primer piso

Av. Ladrón de Guevara E11-253 y Andalucía

Teléfono: 2976300 Ext. 1066



proceso de búsqueda de configuraciones óptimas, favoreciendo un diseño experimental sistemático.

- El *pipeline* modular desarrollado en *Python* garantiza reproducibilidad, escalabilidad y posibilidad de extensión hacia nuevas arquitecturas y fuentes de datos multimodales.

En conjunto, este producto establece una base metodológica y computacional sólida para el desarrollo de modelos predictivos espaciales avanzados orientados a la generación de estimaciones continuas del carbono orgánico del suelo en el Ecuador.

6. ACEPTACIÓN

Firma Mateo Soliz en calidad de Servidor Público 5 (denominación del profesional descrito en el contrato) del Proyecto PIS-24-09 y el director del Proyecto David Andrés Donoso Vargas, en calidad de director del Proyecto PIS-24-09, para constancia de la recepción de este producto y su aprobación a entera satisfacción.

Elaborado por:	Aprobado por:
Nombre: Mateo Xavier Soliz Villafuerte Servidor Público 5	Nombre: David Andrés Donoso Vargas Director del Proyecto PIS-24-09